PHISHCROSS: ARSITEKTUR MULTIMODAL CROSS-ATTENTION DENGAN FUSION HEAD RINGAN UNTUK DETEKSI WEBSITE PHISHING PADA DATASET PHISH360

PROPOSAL SKRIPSI

Diajukan sebagai Salah Satu Syarat untuk Melaksanakan
Penelitian Skripsi Program Studi Teknik Informatika
Fakultas Sains dan Teknologi
Universitas Islam Nahdlatul Ulama Jepara

Oleh:

AFRIZAL ILZA MUNADHIF

NIM: 231240001420

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NAHDLATUL ULAMA JEPARA
2026

PERSETUJUAN PEMBIMBING

Yang bertanda tangan di bawah ini menyatakan telah menyetujui Proposal Skripsi mahasiswa:

Nama	:	AFRIZAL ILZA MUNADHIF
NIM	:	231240001420
Program Studi	:	Teknik Informatika
Fakultas	:	Sains dan Teknologi
Judul	:	PHISHCROSS: ARSITEKTUR MULTIMODAL CROSS-ATTENTION DENGAN FUSION HEAD RINGAN UNTUK DETEKSI WEBSITE PHISHING PADA DATASET PHISH360

untuk diujikan dalam sidang Seminar Proposal Skripsi Program Sarjana.

Nama	Tanggal	Tanda Tangan

1. **NUR AENI WIDIASTUTI, S.Pd., M.Kom.** 13 Juli 2026

NIY. 4 870702 16 199

(Pembimbing 1)

2. **AKHMAD KHANIF ZYEN, S.Kom., M.Kom.** 13 Juli 2026

NIY. 3 860421 13 092

(Pembimbing 2)

DAFTAR ISI

PERSETUJUAN PEMBIMBING ii

DAFTAR ISI iii

DAFTAR TABEL v

DAFTAR GAMBAR vi

BAB I PENDAHULUAN 1

A. Latar Belakang 1

B. Rumusan Masalah 4

C. Tujuan Penelitian 5

D. Batasan Masalah 5

E. Manfaat Penelitian 6

F. Sistematika Penulisan 7

BAB II LANDASAN TEORI DAN TINJAUAN PUSTAKA 9

A. Kajian Teori 9

1. Anatomi Serangan *Phishing* dan Taktik *Evasion* 9

2. Komponen Halaman Web 10

3. Jaringan Saraf Tiruan dan *Deep Learning* 11

4. Konsep Multimodal *Deep Learning* Dalam Keamanan Siber 12

5. Pengekstraksi Fitur Kelas Ringan (*Lightweight Encoders*) 13

6. Mekanisme *Attention* dan *Cross-Attention* 15

7. *Modality Dropout* dan Regularisasi *Robustness* 17

B. Penelitian Terdahulu 18

C. Kerangka Berpikir 21

D. Hipotesis Penelitian 24

BAB III METODOLOGI PENELITIAN 26
A. Jenis dan Pendekatan Penelitian 27
B. Waktu dan Tempat Penelitian 27
C. Dataset dan Pembagian Data 27
D. Spesifikasi Perangkat Keras dan Perangkat Lunak 29
E. Teknik Analisis Data 31
1. Arsitektur Model *PhishCross* 31
2. Strategi *Training* 39
3. Desain Eksperimen 41
4. Pengujian Efisiensi dan Konversi ONNX 43
5. Metrik Evaluasi 44
6. Kriteria Pengujian Hipotesis 46
DAFTAR PUSTAKA 47
LAMPIRAN 56

DAFTAR TABEL

Tabel 2.1 Ringkasan Penelitian Terdahulu 18
Tabel 3.1 Skema Pembagian Dataset Phish360 28
Tabel 3.2 Parameter dan *Hyperparameter* Pelatihan 39
Tabel 3.3 Pemetaan 14 Konfigurasi Eksperimen 42
Tabel 3.4 Matriks Metrik Evaluasi Kinerja Model 44

DAFTAR GAMBAR

Gambar 2.1 Diagram Alur Kerangka Berpikir Penelitian 22
Gambar 3.1 Alur Penelitian 26
Gambar 3.2 Skema Pembagian Dataset..... 29
Gambar 3.3 Arsitektur Model *PhishCross* 31
Gambar 3.4 Detail Pure Cross-Attention..... 36
Gambar 3.5 Arsitektur Model Pembanding..... 38

BAB I
PENDAHULUAN

A. Latar Belakang

Perkembangan pesat interaksi digital dan transaksi elektronik dalam lingkup global, secara langsung berbanding lurus dengan eskalasi ancaman kejahatan siber. Di antara berbagai ancaman tersebut, *phishing* telah menjadi salah satu bentuk penipuan digital yang paling meluas dan mengakibatkan kerugian finansial yang sangat signifikan (Tang & Mahmoud, 2021; Thakur et al., 2023). Secara definitif, *phishing* merupakan bentuk rekayasa sosial (*social engineering*) dengan cara penyerang menyamar sebagai entitas yang sah untuk mengelabui korban agar menyerahkan data sensitif seperti kredensial perbankan dan kata sandi (Ahmad et al., 2025; Anti-Phishing Working Group, 2024). Eskalasi ancaman siber ini tidak hanya menargetkan sektor finansial konvensional, tetapi juga telah berekspansi secara meluas ke berbagai infrastruktur digital kritis, seperti sistem rekam medis dan layanan kesehatan pintar (Ibrahim et al., 2024; Qureshi & Koo, 2026).

Pada era modern ini, ancaman *phishing* telah berevolusi menjadi manipulasi visual dan tekstual yang sangat kompleks. Pendekatan deteksi konvensional berbasis daftar hitam (*blacklist*) tidak lagi memadai untuk menangani evolusi taktik ini (Gupta et al., 2018; Moghimi & Varjani, 2016). Penyerang siber saat ini sering kali menyembunyikan kode HTML berbahaya menggunakan teknik pengaburan (*obfuscation*), namun tetap mempertahankan kemiripan visual logo dan tata letak merek terkenal agar terlihat sah bagi korban. Akibatnya, model deteksi yang hanya menganalisis satu aspek halaman memiliki titik buta (*blind spot*) yang mudah dieksploitasi oleh penyerang (Duy et al., 2024; Li et al., 2025). Berbagai model klasifikasi berbasis *deep learning* unimodal terus dikembangkan untuk menganalisis URL berbahaya atau konten halaman secara terpisah (Aljofey et al., 2020; Alshingiti et al., 2023; Barik et al., 2025; Haq et al., 2024; Ogawa et al., 2022; Tang & Mahmoud, 2022; Yang et al., 2019; Zara et al., 2024). Meskipun demikian, pemrosesan HTML dalam penelitian ini membatasi ekstraksi fitur pada dokumen

kode marka statis yang diperoleh secara lokal. Sehingga penanganan taktik pengelabuan tingkat lanjut (*evasion tactics*) berbasis *client-side rendering* dinamis, seperti *React* atau *Vue* diposisikan sebagai cakupan pengembangan di masa mendatang. Namun, keterbatasan analisis unimodal tersebut menegaskan bahwa pendekatan multimodal yang mengombinasikan URL, teks HTML, dan gambar tangkapan layar (*screenshot*) menjadi arah riset yang krusial, karena mampu memberikan analisis silang yang komprehensif (Aksoy et al., 2026).

Meskipun pendekatan multimodal telah banyak diadopsi, kajian literatur terkini menunjukkan bahwa penggabungan berbagai modalitas tersebut masih menghadapi beberapa kendala. Penelitian oleh Almakhamreh & Bozkir (2026a) melalui arsitektur *CrossPhire* telah menunjukkan keberhasilan penggabungan modalitas URL, HTML, dan *screenshot* pada dataset Phish360. Namun, fusi multimodal dalam *CrossPhire* masih bertumpu pada penggabungan fitur linier (*concatenation*) secara statis atau fusi tahap akhir (*late fusion*). Kondisi ini menimbulkan kesenjangan metodologi fusi (*fusion gap*), sehingga relasi lintas-modalitas tidak dimodelkan secara aktif. Informasi dari satu modalitas tidak digunakan untuk membimbing pencarian bukti pada modalitas lainnya. Di sisi lain, interaksi visi-bahasa yang dinamis telah dieksplorasi oleh Li et al. (2025) pada *FedPhishLLM* dan Cao et al. (2025) pada *PhishAgent*, tetapi metode tersebut mengandalkan *large language models* (LLM) yang membutuhkan kapasitas komputasi yang sangat besar. Oleh karena itu, diperlukan mekanisme fusi dinamis yang lebih ringan tanpa bergantung pada LLM berskala besar.

Di samping tantangan metodologi fusi, terdapat pula kendala komputasi yang menghalangi sistem keamanan untuk bekerja secara proaktif. Beberapa penelitian terdahulu telah mencoba merancang model deteksi *phishing* yang dapat dijalankan secara lokal di *client-side* baik menggunakan model klasifikasi ringan maupun integrasi ekstensi peramban (*browser extension*) (Faris & Yazid, 2021; Suwarno et al., 2026; Syafiq Rohmat Rose et al., 2022). Sebagai contoh, Roy & Nilizadeh (2026) mengembangkan *PhishLang* berbasis *MobileBERT* untuk pemrosesan teks lokal, sedangkan Lakshmi & P (2026) merancang *LightPhishAI* untuk perangkat *edge* dengan pengekstraksi visual yang efisien. Meskipun demikian, model-model

lokal tersebut umumnya masih bersifat unimodal atau sangat bergantung pada kueri metadata eksternal seperti kueri API WHOIS atau status sertifikat SSL. Ketergantungan ini menimbulkan kesenjangan komputasi (*computational gap*) berupa latensi jaringan tambahan ketika menghubungi API luar, kerentanan terhadap kegagalan koneksi server eksternal, serta potensi pelanggaran privasi riwayat penelusuran (*browsing history*) pengguna akhir. Untuk menjembatani kesenjangan komputasi tersebut, diperlukan model multimodal mandiri yang hanya memproses fitur konten lokal halaman web tanpa kueri eksternal.

Tantangan komputasi tersebut berkaitan erat dengan aspek ketahanan model terhadap manipulasi data. Pada kondisi aktual, model multimodal sering kali dihadapkan pada situasi hilangnya salah satu modalitas input (*missing modality*). Studi terdahulu seperti *CrossPhire* (Almakhamreh & Bozkir, 2026a) mengidentifikasi bahwa kegagalan memuat *screenshot* atau manipulasi kode HTML oleh penyerang dapat menurunkan akurasi model secara drastis. Sebagai mitigasi, penggunaan regularisasi seperti *modality dropout* 26(Srivastava et al., 2014) terbukti mampu meningkatkan ketahanan model multimodal pada berbagai domain umum. Namun, terdapat kesenjangan ketahanan (*robustness gap*) pada arsitektur fusi asimetris bersikuens pendek. Dampak teknik ini belum banyak diuji ketika tumpukan *Key/Value* hanya berisi dua vektor ringkasan modalitas, sehingga manfaat regularisasi dan risiko stokastisitas gradiennya perlu dievaluasi secara empiris pada ranah deteksi *phishing*.

Merespons ketiga kesenjangan tersebut, penelitian ini mengusulkan pengembangan arsitektur *PhishCross (lightweight multimodal cross-attention*). Arsitektur ini dirancang untuk menguji fusi asimetris ringkas pada model multimodal yang hanya memproses fitur konten lokal halaman web (URL, HTML, dan *screenshot*) tanpa kueri eksternal demi menjaga privasi. Seluruh eksperimen pelatihan dan evaluasi model dilakukan pada dataset publik Phish360. *PhishCross* bekerja dengan menginteraksikan teks HTML dan modalitas lainnya melalui mekanisme atensi silang (*cross-attention*) asimetris. Pada mekanisme ini, HTML bertindak sebagai *query* yang mencari informasi relevan dari URL dan visual tanpa melakukan atensi mandiri (*self-attention*) terhadap representasinya sendiri. Namun,

HTML tetap dialirkan langsung ke kepala klasifikasi (*classifier head*) melalui jalur residual. Oleh karena itu, arsitektur ini lebih tepat disebut sebagai HTML-*queried cross-attention with residual bypass*, bukan arsitektur yang hanya mengandalkan *cross-attention*. Pada penelitian ini, istilah ringan (*lightweight*) secara khusus merujuk pada komponen fusi dan *classifier head* yang dilatih, bukan pada keseluruhan *footprint* memori sistem. Untuk menguji efisiensi komputasi, model diekspor ke format ONNX agar dapat dijalankan secara lokal pada perangkat CPU pengguna. Selain itu, penelitian ini secara khusus mengevaluasi dampak *modality dropout* melalui eksperimen ablasi kontrol untuk mengungkap karakteristik ketahanan *PhishCross* ketika dihadapkan pada skenario *missing modality*. Dengan karakteristik fusi asimetris yang berorientasi pada presisi tinggi ini, penelitian ini diharapkan dapat memberikan referensi teoretis baru bagi komunitas ilmiah di bidang keamanan siber (*cybersecurity*), pembelajaran mendalam (*deep learning*), visi komputer (*computer vision*), dan pemrosesan bahasa alami (*natural language processing*) serta solusi praktis bagi pengembangan perangkat lunak pelindung siber yang efisien dan menjaga privasi pengguna.

B. Rumusan Masalah

1. Bagaimana merancang dan membangun arsitektur *PhishCross* yang mampu mengimplementasikan mekanisme dinamis *cross-modal attention* secara ringan untuk mendeteksi website *phishing* dan berpotensi diterapkan pada lingkungan lokal atau *client-side*?
2. Bagaimana profil ketahanan model *PhishCross* pada protokol pelatihan yang menerapkan strategi *modality dropout* ketika dihadapkan pada skenario *missing modality*?
3. Bagaimana komparasi performa arsitektur *PhishCross* dibandingkan dengan model pembanding yang diuji dalam penelitian ini, yaitu model unimodal (`url_only`, `html_only`, `image_only`), serta metode fusi multimodal *concat* dan *attention*, dalam aspek *F1-Score*, presisi, jumlah parameter, dan metrik komputasional lainnya?

C. Tujuan Penelitian

1. Mengembangkan arsitektur *PhishCross* berbasis *cross-attention* ringan yang menyatukan pemahaman fitur URL, HTML, dan *screenshot* guna memfasilitasi deteksi *phishing* yang berpotensi dijalankan pada lingkungan lokal atau *client-side*.
2. Mengevaluasi *robustness* model pada protokol pelatihan yang menerapkan *modality dropout* ketika dihadapkan pada skenario *missing modality*.
3. Mengevaluasi profil performa klasifikasi dan efisiensi komputasi *PhishCross* secara komparatif terhadap model unimodal, metode fusi *concat*, dan metode fusi *attention*.

D. Batasan Masalah

1. Modalitas yang Digabungkan

Model *PhishCross* dirancang untuk analisis berbasis konten (*content-based analysis*), yaitu URL mentah, teks HTML hasil ekstraksi teks yang terlihat (*visible text*), dan *screenshot*.

2. Tanpa Metadata Eksternal

Penelitian ini tidak menggunakan fitur metadata eksternal seperti umur domain, WHOIS, atau sertifikat SSL. Pembatasan ini dipilih agar model lebih dekat dengan skenario lokal yang tidak bergantung pada *query* API eksternal.

3. Penyediaan Dataset

Seluruh skenario pelatihan (*training*), penyesuaian (*tuning*), dan pengujian dieksekusi secara eksklusif pada dataset publik, yakni dataset Phish360.

4. Lingkungan Evaluasi Kecepatan

Pengujian efisiensi komputasi model diukur berdasarkan metrik arsitektural dan pengujian lokal ONNX *runtime*. Klaim ringan pada penelitian ini secara khusus merujuk pada kompleksitas *fusion layer* dan *classifier head* dengan jumlah parameter *trainable* di bawah 500 ribu, dan tidak mencerminkan keseluruhan *footprint* memori sistem yang mencakup *encoder* beku. Selain itu, penelitian ini belum mengimplementasikan model sebagai *browser extension* produksi, sehingga evaluasi kecepatan dibatasi pada lingkungan pengujian lokal.

E. Manfaat Penelitian

1. Manfaat Teoritis

Hasil penelitian ini diharapkan mampu memberikan referensi teoretis baru bagi komunitas ilmiah di bidang *cybersecurity*, *deep learning*, *computer vision*, dan *natural language processing.* Referensi teoretis ini memetakan irisan komprehensif dari keempat bidang tersebut berupa *natural language processing* yang diimplementasikan pada ekstraksi representasi semantik HTML dan URL, sedangkan *computer vision* diaplikasikan pada pengolahan fitur *screenshot*. Dimensi-dimensi informasi tersebut kemudian diintegrasikan melalui inovasi *fusi cross-attention* asimetris bersikuens pendek dan regulasi *modality dropout* sebagai representasi dari keilmuan *deep learning*. Pada akhirnya, perpaduan multidisiplin ini bermuara pada pembentukan sistem deteksi *phishing* yang presisi guna memperkokoh ranah *cybersecurity*.

2. Manfaat Praktis

Sedangkan dari sisi praktis, penelitian ini mampu memberikan wawasan komparatif dan kontribusi ilmiah bagi pengembang perangkat lunak *cybersecurity* serta penyedia layanan perlindungan web untuk:

a. Menjadikan arsitektur *PhishCross* sebagai referensi rancang bangun dalam mendesain model deteksi *phishing* multimodal yang efisien di *client-side*.

b. Memberikan panduan teknis dalam menyusun model klasifikasi berbasis fitur konten lokal peramban (URL, teks, gambar) guna mendukung proteksi yang menjaga privasi pengguna akhir.

c. Menyediakan data empiris mengenai profil *robustness model* ketika menghadapi kendala jaringan atau kegagalan pemuatan salah satu modalitas masukan saat inferensi.

d. Menawarkan solusi alternatif penekanan *false positive* melalui pemanfaatan mekanisme *cross-attention* asimetris pada deteksi berbasis peramban.

F. Sistematika Penulisan

1. Bab I Pendahuluan

Bab ini menguraikan landasan awal penelitian yang mencakup latar belakang permasalahan terkait maraknya serangan *phishing* dengan *evasion tactics*. Berangkat dari latar belakang tersebut, bab ini mencakup perumusan permasalahan utama, menetapkan tujuan dan batasan ruang lingkup eksperimen, serta menjabarkan manfaat yang diharapkan dari pengembangan arsitektur *PhishCross*, baik secara teoretis maupun praktis.

2. Bab II Tinjauan Pustaka

Bab ini memaparkan landasan teori yang menjadi fondasi teknis penelitian, meliputi konsep dasar *phishing*, *natural language processing*, *computer vision*, serta komponen arsitektur seperti *MobileNetV3*, *MiniLM*, dan mekanisme *cross-attention*. Selain itu, bab ini secara kritis menguraikan kajian terhadap penelitian-penelitian terdahulu yang relevan, menyusun kerangka berpikir konseptual, dan diakhiri dengan perumusan hipotesis eksperimental yang akan diuji.

3. Bab III Metodologi Penelitian

Bab ini menjelaskan secara terperinci pendekatan dan tahapan sistematis yang digunakan dalam pelaksanaan eksperimen. Pembahasan di dalamnya mencakup penggunaan dataset Phish360 beserta skema pembagiannya, spesifikasi perangkat keras dan perangkat lunak, detail rancang bangun arsitektur fusi multimodal *PhishCross*, hingga penerapan teknik *modality dropout*. Bab ini juga memetakan desain pengujian komparatif dan menentukan metrik evaluasi yang digunakan sebagai tolak ukur kinerja.

BAB II
LANDASAN TEORI DAN TINJAUAN PUSTAKA

A. Kajian Teori

1. Anatomi Serangan *Phishing* dan Taktik *Evasion*

Secara fundamental, *phishing* merupakan bentuk kejahatan siber yang mengandalkan *social engineering* untuk memanipulasi psikologi korban agar menyerahkan data sensitif secara sukarela (Li et al., 2023). Serangan ini umumnya dikirimkan melalui saluran komunikasi elektronik seperti email, pesan instan, atau iklan palsu yang dirancang sedemikian rupa untuk membangkitkan rasa urgensi, ketakutan, atau otoritas palsu pada diri korban (Wangchuk & Gonsalves, 2025). Korban yang terpancing kemudian diarahkan untuk membuka tautan berbahaya menuju situs web tiruan yang mereplikasi tampilan portal resmi dari institusi sasaran (Anti-Phishing Working Group, 2024). Variasi serangan *phishing* saat ini tidak hanya menargetkan halaman web statis tetapi juga merambah ke penipuan multimodal lainnya seperti *voice phishing* yang menyatukan analisis suara dan teks (Kim et al., 2025).

Dalam perkembangannya, penyerang menerapkan berbagai *evasion tactics* untuk menghindari filter keamanan otomatis. Salah satu taktik tersebut adalah *JavaScript-based obfuscation* dan *cloaking*. Melalui taktik ini, kode sumber halaman web dienkripsi secara dinamis atau disembunyikan agar pemindai otomatis (*crawling bot*) hanya membaca halaman kosong. Di sisi lain peramban pengguna akhir tetap merender halaman penipuan secara utuh (Lee et al., 2024; Li et al., 2023). Selain itu, penyerang memanfaatkan pembuatan halaman di sisi klien (*client-side rendering*) menggunakan framework *JavaScript* modern seperti *React* atau *Vue* untuk menunda pembentukan dokumen halaman (*dynamic DOM rendering*) hingga halaman dimuat sepenuhnya (Yoon et al., 2024).

Selain *evasion tactics* pada tingkat kode dan struktur dokumen, penyerang juga menerapkan taktik manipulasi visual pada alamat web untuk mengelabui pengguna. Sebagai contoh, penggunaan serangan karakter homograf (*homoglyph attack*) yang memanfaatkan nama domain internasional berbasis *Punycode* untuk meniru karakter alfabet Latin standar dengan huruf *non*-ASCII seperti alfabet Sirilik yang secara visual identik. Manipulasi ini secara efektif mampu memalsukan kredibilitas URL di mata korban (Ali & Rezvani, 2026; Duy et al., 2024).

2. Komponen Halaman Web

Keabsahan suatu halaman web dapat dideteksi secara komprehensif dengan membedah tiga komponen struktural utamanya (Almakhamreh & Bozkir, 2026a):

a. URL (*Uniform Resource Locator*)

Alamat unik penunjuk lokasi sumber daya di internet yang tersusun atas komponen protokol seperti HTTP atau HTTPS, nama domain utama (*Second-Level Domain*/SLD), subdomain, nama direktori (*path*), dan parameter kueri (Asiri et al., 2024). Penyerang siber memanipulasi komponen-komponen tersebut melalui *typosquatting*, pembentukan subdomain bertumpuk (misalnya `secure.login.paypal.com-update.net`), atau penyisipan alamat IP mentah untuk memotong reputasi domain (Butnaru et al., 2021; Prasad & Chandra, 2024).

b. HTML (*Hypertext Markup Language*)

Struktur kode marka yang mendefinisikan elemen semantik dokumen web dalam bentuk pohon *document object model* (DOM). Elemen kritis HTML meliputi tag aksi pencatatan kredensial seperti tag `<form>` dan `<input>` yang mengarahkan data masukan ke server penyerang, serta *visible text* yang memuat konteks linguistik halaman (Yoon et al., 2024; Yuan et al., 2026).

c. Visual *Screenshot*

Citra dua dimensi yang merepresentasikan visualisasi *end-to-end* yang dilihat oleh pengguna akhir. Informasi visual ini memuat pola geometris tata letak tombol, skema palet warna merek, dan penempatan kotak teks input yang sering kali ditiru oleh penyerang untuk memperdaya kognisi visual korban (Duy et al., 2024).

3. Jaringan Saraf Tiruan dan *Deep Learning*

Jaringan Saraf Tiruan (*Artificial Neural Network*/ANN) merupakan paradigma komputasi yang terinspirasi dari jaringan neuron biologis pada otak manusia untuk memetakan hubungan non-linear antara input dan output. Masukan diproses melalui operasi proyeksi linear yang dikombinasikan dengan bias dan fungsi aktivasi non-linear:

$$h = f(W \cdot x + b) \quad (1)$$

di mana W adalah matriks bobot, b adalah vektor bias, dan f adalah fungsi aktivasi non-linear seperti *rectified linear unit* (ReLU) atau *Sigmoid* yang bertugas memperkenalkan non-linearitas ke dalam model agar dapat mempelajari fungsi batas keputusan yang kompleks (Srivastava et al., 2014). Dibandingkan pendekatan pembelajaran mesin tradisional, *deep learning* menawarkan ekstraksi fitur representasi secara hierarkis dan otomatis, sehingga cocok untuk menangkap pola URL, HTML, dan visual yang kompleks pada deteksi *phishing*.

Deep learning merupakan pengembangan ANN dengan menumpuk banyak lapisan tersembunyi (*hidden layers*) untuk mengekstrak fitur representasi abstrak secara hierarkis tanpa memerlukan rekayasa fitur manual (*feature engineering*) (Srivastava et al., 2014). Proses pelatihan model *deep learning* dikontrol oleh kalkulasi fungsi kerugian (*loss function*) seperti *Binary Cross Entropy Loss* untuk mengukur tingkat kesalahan prediksi model:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)] \quad (2)$$

di mana y_i adalah label aktual dan $\hat{y}_i$ adalah probabilitas prediksi model. Nilai kerugian tersebut diperambatkan balik (*backpropagation*) melintasi lapisan model untuk memperbarui nilai parameter bobot menggunakan algoritma optimasi penurun gradien adaptif seperti *AdamW* yang menyertakan regulasi pemotongan bobot (*decoupled weight decay*).

4. Konsep Multimodal *Deep Learning* Dalam Keamanan Siber

Pendekatan multimodal *deep learning* mengintegrasikan representasi fitur dari beberapa saluran sensorik atau sumber informasi masukan yang berbeda untuk memecahkan satu tugas klasifikasi (Ali & Rezvani, 2026; Lee et al., 2024). Penggabungan ini bertujuan untuk memodelkan koordinasi antar-modalitas guna menangkap hubungan komplementer antar-fitur. Taksonomi fusi multimodal umumnya terbagi menjadi tiga kategori (Aksoy et al., 2026):

a. Early Fusion (*Feature-level*)

Penggabungan beberapa representasi modalitas secara langsung seperti *concatenation* pada tahap awal sebelum dialirkan ke pengklasifikasi.

b. *Intermediate Fusion* (*Representation-level*)

Penggabungan representasi modalitas pada *hidden layers* di dalam jaringan saraf, memungkinkan interaksi fitur yang lebih kompleks.

c. *Late Fusion* (*Decision-level*)

Penggabungan hasil prediksi probabilitas akhir dari masing-masing modalitas menggunakan teknik pemungutan suara (*voting*) atau rata-rata. Pada ranah keamanan siber, pembelajaran multimodal telah digunakan untuk meningkatkan koordinasi informasi pada deteksi pemalsuan citra sensor IoT (Nasir et al., 2026), klasifikasi kerentanan kode sumber perangkat lunak (Jin et al., 2025), serta deteksi video

rekayasa wajah (*deepfake*) berbasis sensor dengan *cross-attention* (Waseem et al., 2026)

Rangkaian studi tersebut menunjukkan bahwa kekuatan utama pembelajaran multimodal terletak pada kemampuannya memadukan bukti yang saling melengkapi dari berbagai sumber. Namun, keuntungan ini juga menimbulkan tantangan baru ketika salah satu modalitas menjadi terlalu dominan atau tidak tersedia saat inferensi.

Salah satu tantangan utama dalam pembelajaran multimodal adalah masalah ketidakseimbangan modalitas (*modality imbalance*), di mana model cenderung hanya berfokus pada modalitas yang paling dominan selama pelatihan, sehingga mengabaikan modalitas lainnya. Akibatnya, sistem menjadi sangat rentan mengalami kegagalan deteksi jika modalitas dominan tersebut hilang atau dimanipulasi oleh penyerang (Duy et al., 2024; Yuan et al., 2026)

5. Pengekstraksi Fitur Kelas Ringan (*Lightweight Encoders*)

Rancang bangun model deteksi siber yang efisien di sisi klien menuntut penggunaan modul ekstraktor fitur pra-latih yang kompak namun memiliki daya ekspresi representasi yang tinggi:

a. URL Char-CNN 1D

Jaringan saraf konvolusional satu dimensi yang memproses urutan karakter URL secara langsung tanpa bergantung pada kamus kosakata luar (Butnaru et al., 2021). Proses konvolusi linear satu dimensi bekerja dengan menggeser filter konvolusi melintasi matriks karakter URL:

$$y_i = f(w \cdot x_{i:i+k-1} + b) \quad (3)$$

dimana w mewakili filter dengan kernel k (kernel 3, 5, dan 7) dan $x_{i:i+k-1}$ mewakili urutan karakter lokal (n-gram). Operasi *global max pooling* kemudian mengambil nilai maksimum dari setiap filter konvolusi:

$$\hat{y}_c = max_i(y_{i,c}) \quad (4)$$

untuk menyaring pola anomali karakter terkuat seperti kemunculan kata kunci penipuan terlepas dari posisinya pada URL (Asiri et al., 2024).

b. *Sentence-Transformers all-MiniLM-L6-v2*

Model bahasa terkompresi yang dilatih menggunakan teknik distilasi pengetahuan (*knowledge distillation*) dari model guru *BERT* yang berukuran raksasa (W. Wang et al., 2020). Model siswa *MiniLM* secara khusus dipilih karena bobotnya yang sangat ringan, yakni hanya memuat 22 juta parameter, jauh lebih efisien dibandingkan dengan model kompresi alternatif seperti *DistilBERT* yang memiliki 66 juta parameter. Dalam proses pelatihannya, model ini dioptimasi dengan *loss function* gabungan yang meminimalkan *Kullback-Leibler* (KL *divergence*) dari distribusi atensi (*attention distributions*) model guru dengan parameter temperatur $\mathcal{T}$:

$$\mathcal{L}_{\text{KD}} = (1-\alpha)\mathcal{L}_{\text{student}} + \alpha\mathcal{T}^2 \sum_i p_{\text{teacher}}(i) \log\left(\frac{p_{\text{teacher}}(i)}{p_{\text{student}}(i)}\right) \quad (5)$$

Teknik ini mentransfer pola hubungan semantik antar-kata secara presisi tanpa memerlukan parameter yang besar, sehingga mampu menghasilkan representasi HTML 384 dimensi yang sangat efisien (W. Wang et al., 2020). Selain model berbasis *Sentence-Transformers*, penggunaan *small language models* (SLMs) mulai banyak diteliti untuk menganalisis teks secara lokal karena menawarkan *trade-off* yang optimal antara privasi, kecepatan inferensi, dan akurasi deteksi (Goldenits et al., 2026).

c. *MobileNetV3-Small*

Arsitektur *computer vision* ringan yang menggantikan konvolusi standar dengan *depthwise separable convolution* untuk mereduksi beban komputasi perkalian matriks (Howard et al., 2019). Rasio parameter komputasi antara *depthwise separable convolution* dan

konvolusi standar pada kernel berdimensi D_K dengan saluran output N didefinisikan sebagai:

$$\text{Rasio Perbandingan} = \frac{1}{N} + \frac{1}{D_K^2} \tag{6}$$

Dengan kernel 3×3 ($D_K = 3$), teknik ini menghemat parameter hingga 8 hingga 9 kali lebih sedikit (Howard et al., 2019). Model ini juga dilengkapi dengan blok *Squeeze-and-Excitation* (SE) yang menerapkan perhatian saluran (*channel-wise attention*). Operasi *squeeze* mereduksi spasial dimensi citra melalui *global average pooling*:

$$z_c = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} u_c\,(i, j) \tag{7}$$

diikuti oleh operasi *excitation* menggunakan MLP kecil beraktivasi ReLU (δ) dan *Sigmoid* (σ) untuk menghitung bobot penting setiap saluran:

$$s = \sigma(W_2 \delta(W_1 z)) \tag{8}$$

Vektor bobot ini dikalikan kembali ke fitur spasial asli citra tangkapan layar untuk memprioritaskan fitur spasial visual yang paling dominan seperti area logo (Azhar et al., 2026; Howard et al., 2019). Secara keseluruhan model *MobileNetV3-Small* ini digunakan karena menghasilkan vektor fitur visual berdimensi 576 dengan efisiensi parameter yang tinggi.

6. Mekanisme *Attention* dan *Cross-Attention*

Mekanisme *attention* pertama kali diajukan oleh Bahdanau et al. (2014) dalam bentuk *additive attention*, dan dikembangkan menjadi *multiplicative/dot-product attention* oleh Luong et al. (2015) untuk menghitung keselarasan dinamis antar-sekuens. Konsep ini kemudian dipopulerkan oleh Vaswani et al. (2017) melalui arsitektur *transformer* berbasis *self-attention*. Formulasi utama *Scaled Dot-Product Attention* didefinisikan sebagai:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (9)$$

dengan matriks *Query* (Q), *Key* (K), dan *Value* (V) diperoleh melalui proyeksi linear dari representasi fitur masukan menggunakan matriks bobot latih (W^Q, W^K, W^V) (Vaswani et al., 2017). Faktor skala pembagi $\sqrt{d_k}$ (dengan d_k mewakili dimensi proyeksi) sangat penting secara matematis. Tanpa pembagian skala ini, untuk nilai dimensi d_k yang sangat besar, hasil perkalian titik QK^T akan bernilai sangat ekstrim. Kondisi ini mendorong fungsi *softmax* masuk ke wilayah dengan gradien yang sangat kecil (*vanishing gradient*) yang merusak proses pembaruan parameter (Vaswani et al., 2017).

Perbedaan mendasar antara *self-attention* dan *cross-attention* terletak pada asal usul data masukannya. Pada *self-attention*, seluruh matriks Q, K, dan V diproyeksikan dari modalitas tunggal yang sama. Sebaliknya, pada *cross-attention* asimetris, matriks Q diproyeksikan dari satu modalitas utama seperti representasi HTML, sedangkan K dan V diproyeksikan dari tumpukan modalitas pendukung lainnya seperti fitur URL dan visual screenshot (Lu et al., 2019; X. Wang et al., 2025):

$$Q = h_{\text{query}}W^Q, K = [h_{\text{key1}}; h_{\text{key2}}]W^K, V = [h_{\text{val1}}; h_{\text{val2}}]W^V \quad (10)$$

Mekanisme ini memfasilitasi pemodelan interaksi dinamis di mana modalitas *Query* secara aktif menyaring dan mencari bukti silang (*cross-validation*) dari modalitas kunci/nilai pendukung (Lu et al., 2019). *Multi-Head Attention* (MHA) memperluas operasi ini dengan menjalankan proyeksi perhatian secara paralel pada beberapa kepala independen untuk menangkap keterkaitan fitur pada berbagai subruang representasi yang berbeda secara simultan (Vaswani et al., 2017). Namun, ekspresivitas *cross-attention* sangat dipengaruhi oleh panjang sekuens K/V. Jika K/V hanya berisi dua vektor ringkasan modalitas, operasi *softmax* pada dasarnya menghasilkan bobot interpolasi atas dua sumber informasi, bukan penyelarasan token atau *patch* yang granular. Mekanisme *cross-attention* asimetris ini telah diadopsi secara luas di berbagai bidang komputasi, seperti segmentasi pemandangan kota

(Zhong et al., 2025), klasifikasi citra penginderaan jauh (X. Liu et al., 2026), deteksi awan satelit (J. Zhang et al., 2022), robotika seluler (Jin et al., 2025), serta sistem fusi diagnosis medis parkinson (Ravichandran et al., 2026).

7. *Modality Dropout* dan Regularisasi *Robustness*

Untuk meningkatkan *robustness* model terhadap skenario *missing modality*, diterapkan teknik regularisasi *modality dropout* selama pelatihan (R. Lin & Hu, 2023). Teknik ini secara acak menonaktifkan seluruh fitur dari suatu modalitas dengan probabilitas tertentu menggunakan masker Bernoulli (Srivastava et al., 2014):

$$\hat{h}_{\text{modal}} = m \cdot h_{\text{modal}}, m \sim \text{Bernoulli}(1-p) \quad (11)$$

dengan p adalah probabilitas *dropout* modalitas. Hal ini memaksa model untuk mempelajari representasi fitur alternatif yang redundan pada modalitas lain (R. Lin & Hu, 2023; Woo et al., 2023). Penguatan *robustness* terhadap *missing modality* merupakan topik riset krusial di berbagai ranah aplikasi, seperti sensor pakai kesehatan (Cisse & Ishimaru, 2026), analisis medis pediatrik (Solanes et al., 2026), estimasi kualitas estetika gambar (X. Zhang et al., 2022), *federated learning* (Xiong & Dai, 2026), serta pemodelan multi-view parsial (C. Zhang et al., 2019).

Namun, penerapan *modality dropout* memiliki risiko ketidakstabilan teoretis ketika diterapkan pada arsitektur *cross-attention* asimetris dengan panjang sekuens kunci/nilai yang sangat pendek ($K/V = 2$). Ketika salah satu atau kedua modalitas kunci dilumpuhkan (*zeroed-out)*, secara matematis fungsi *softmax* tetap menghasilkan keluaran yang valid berupa distribusi bobot seragam yakni $[0,5; 0,5]$, alih-alih mengalami kegagalan numerik pembagian dengan nol.

Namun, pada sekuens kunci/nilai pendek, fenomena hilangnya kunci ini secara stokastik kerap terjadi selama pelatihan. Akibatnya, matriks proyeksi W^Q, W^K, W^V dapat menerima sinyal gradien yang tidak konsisten antar-batch (terkadang berupa atensi lintas-modal yang informatif, terkadang berupa atensi seragam yang tidak informatif). Inkonsistensi sinyal pelatihan

inilah, dan bukan kegagalan numerik *softmax*, yang pada akhirnya berpotensi mengganggu stabilitas konvergensi dan memperlebar deviasi performa model (Myagmarsuren et al., 2026; H. Wang et al., 2026). Dengan demikian, *modality dropout* tidak dapat diasumsikan selalu berdampak positif. Pada arsitektur atensi asimetris bersikuens pendek, teknik ini perlu diuji secara empiris karena dapat berfungsi sebagai regularisator sekaligus sumber stokastisitas pelatihan.

B. Penelitian Terdahulu

Dalam lima tahun terakhir, sistem pendeteksi situs *phishing* telah bergerak menjauhi metode konvensional berupa pengecekan *blacklist* dan beralih sepenuhnya menuju pendekatan proaktif berbasis *deep learning*. Evolusi ini dibuktikan dengan munculnya berbagai variasi strategi ekstraksi fitur dan mekanisme fusi yang semakin kompleks. Tabel 2.1 merangkum enam penelitian terdahulu yang paling relevan sebagai landasan ilmiah bagi pengembangan arsitektur *PhishCross*.

Tabel 2.1 Ringkasan Penelitian Terdahulu

No.	Peneliti	Topik Utama	Relevansi thd. PhishCross	Gap Penelitian
1.	Asiri et al. (2024) - PhishTransformer	Analisis URL mandiri berbasis representasi karakter sekuensial.	Rujukan analisis URL tanpa kamus domain eksternal.	Rentan jika berdiri tunggal (*unimodal*) terhadap kamuflase re-direksi dinamis.
2.	Li et al. (2025) - FedPhishLLM	Integrasi LLM multimodal & *Federated Learning*	Bukti efektivitas interaksi multimodal tingkat lanjut.	*Large footprint*, tidak fisibel murni di *client-side*.

No.	Peneliti	Topik Utama	Relevansi thd. PhishCross	Gap Penelitian
3.	Almakhamreh & Bozkir (2026a) - CrossPhire	Pengenalan korpus Phish360 & fusi multimodal linier.	Sumber dataset utama & acuan *baseline* (*concatenation fusion*).	Fusi sebatas gabungan linier statis (*concatenation*), tanpa pemodelan interaksi asimetris dinamis.
4.	Lakshmi & Swetha (2026) - LightPhish AI	Desain deteksi *phishing* ringan (*Edge/IoT*) memadukan URL, metadata, dan gambar.	Landasan efisiensi komputasi & ekstraksi visual ringan.	Ketergantungan pada metadata eksternal (WHOIS) pemicu latensi jaringan.
5.	Roy & Nilizadeh (2026) - PhishLang	Kerangka deteksi lokal berbasis MobileBERT untuk analisis URL & kode.	Bukti kelayakan deteksi lokal di sisi pengguna secara praktis.	Cenderung unimodal tekstual; memiliki *blind spot* terhadap ancaman visual.
6.	Aksoy et al. (2026) - Hybrid Fusion	Optimalisasi efisiensi parameter klasifikasi pada model hibrida multimodal.	Landasan fusi fitur multimodal yang hemat memori.	Belum memisahkan fungsi atensi asimetris secara tegas (HTML sebagai *query* murni).

Hasil penelusuran literatur terdahulu memperlihatkan adanya tren pergeseran metodologi deteksi *phishing* yang sangat jelas. Model deteksi awal umumnya bertumpu pada pendekatan unimodal seperti analisis URL saja (Asiri et al., 2024; Ojewumi et al., 2022; Omari, 2023; Vajrobol et al., 2024) atau analisis teks statis saja. Namun, seiring dengan berkembangnya taktik *obfuscation* kode sumber oleh penyerang, komunitas peneliti mulai mengadopsi kerangka kerja multimodal untuk mengombinasikan URL, teks, dan *screenshot* (Almakhamreh & Bozkir, 2026a). Meskipun terbukti meningkatkan akurasi deteksi, penggabungan modalitas secara linier (*concatenation*) belum memodelkan interaksi korelasi asimetris antar-fitur secara optimal.

Cabang riset visual juga berkembang pesat karena banyak situs *phishing* meniru identitas merek melalui logo, tata letak, dan kemiripan tampilan halaman. *VisualPhishNet* menggunakan kesamaan visual berbasis CNN untuk mendeteksi situs *zero-day* (Abdelnabi et al., 2020), sedangkan *Phishpedia* memadukan deteksi logo dan pencocokan domain untuk mengidentifikasi halaman palsu dari *screenshot* (Y. Lin et al., 2021). Pendekatan lanjutan seperti *PhishIntention* kemudian menambahkan informasi dinamika halaman untuk memperkaya inferensi visual (R. Liu et al., 2022). Dari sisi pengguna, format URL yang ditampilkan juga memengaruhi kemampuan manusia dalam mengenali halaman mencurigakan, sehingga fitur visual dan URL sebaiknya dipahami sebagai bukti yang saling melengkapi, bukan pengganti satu sama lain (Mossano et al., 2023).

Di sisi lain, tuntutan untuk menghadirkan deteksi yang menjaga privasi pengguna mendorong riset ke arah implementasi model lokal di *client-side*. Upaya ini diwujudkan, baik melalui model bahasa terkompresi seperti *PhishLang* (Roy & Nilizadeh, 2026), integrasi *browser extension* (Suwarno et al., 2026; Syafiq Rohmat Rose et al., 2022), maupun integrasi perangkat keras *edge* (Lakshmi & P, 2026). Kendati demikian, model lokal tersebut sering kali masih bergantung pada data eksternal pihak ketiga seperti WHOIS yang menambah latensi komputasi, atau bersifat unimodal sehingga rentan terhadap manipulasi visual logo. Penggunaan model berskala besar seperti *FedPhishLLM* (Li et al., 2025) memberikan akurasi

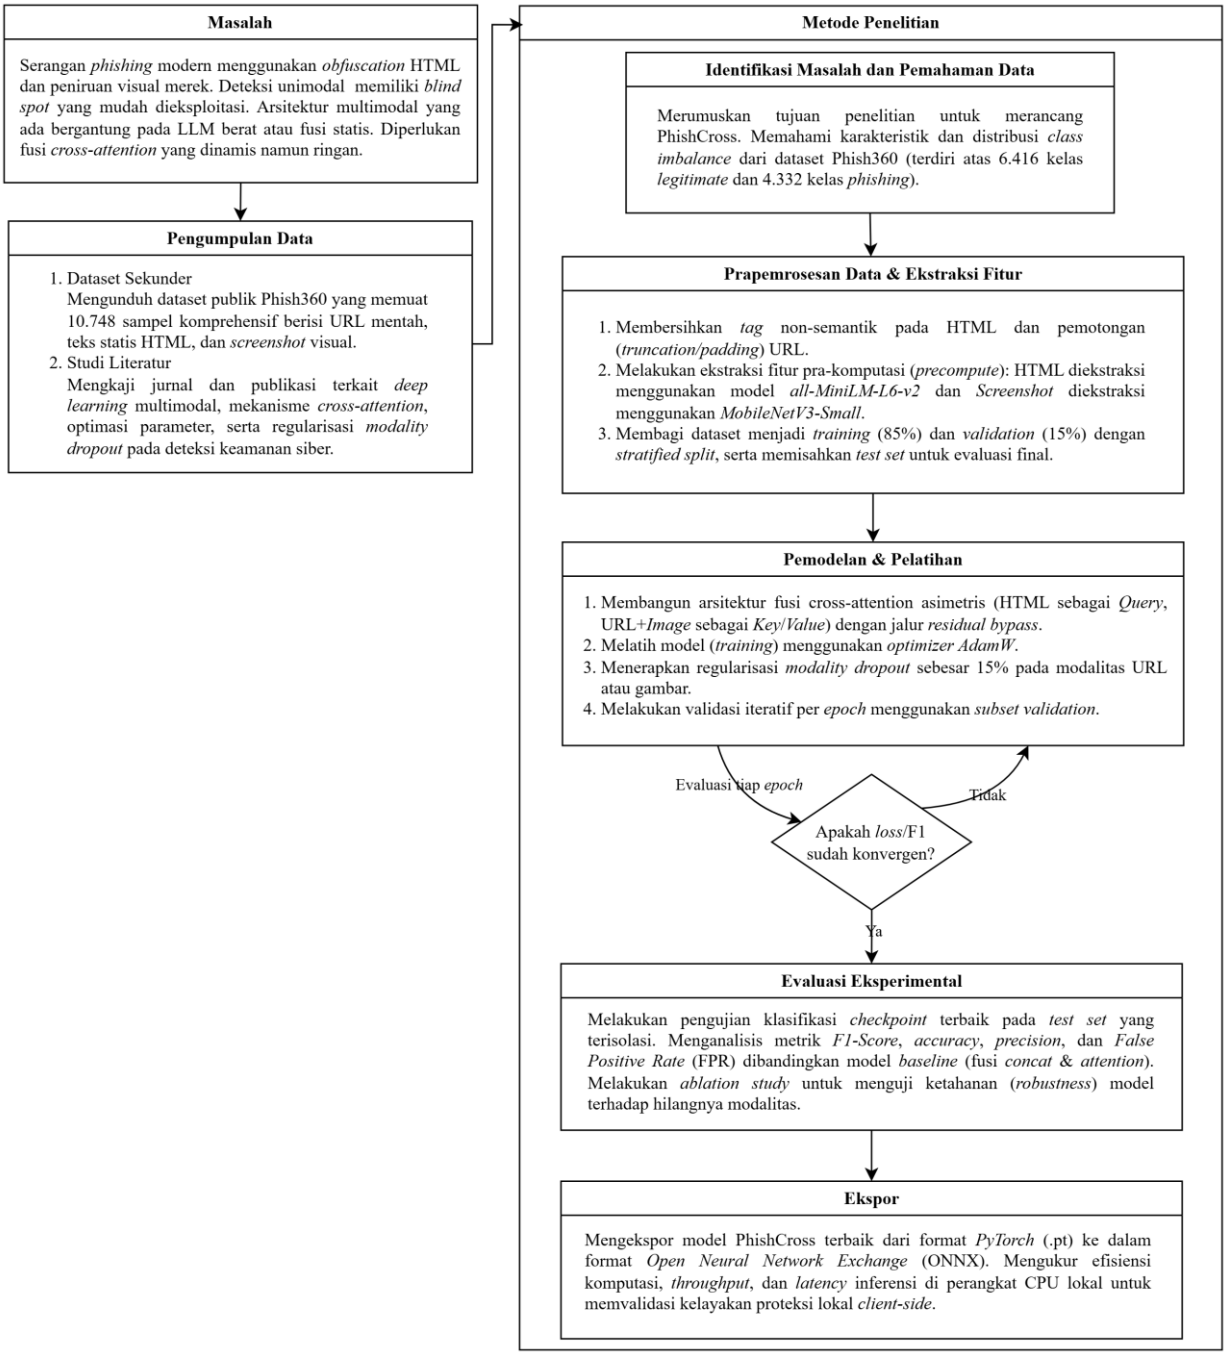
dan penjelasan fusi yang dinamis, namun tidak layak dijalankan pada CPU pengguna biasa karena memori kerja yang dibutuhkan terlalu besar.

Pendekatan ringan berbasis multi-view juga telah dieksplorasi oleh Y. Wang et al. (2023) melalui *transformer* dengan *mixture of experts* untuk deteksi serangan *phishing*. Studi tersebut relevan karena sama-sama menekankan efisiensi model dan pemanfaatan beberapa tampilan fitur. Di luar arsitektur multimodal, penelitian berbasis optimasi dan pembelajaran bertahap seperti Shaiba et al. (2022) serta Prasad & Chandra (2024) menunjukkan bahwa pemilihan fitur dan strategi pelatihan juga berpengaruh terhadap generalisasi deteksi URL. Perbedaannya, *PhishCross* berfokus pada fusi konten lokal URL, HTML, dan *screenshot* tanpa metadata eksternal, serta secara khusus menguji dampak *modality dropout* dan skenario *missing modality*.

Hasil tersebut menegaskan, terdapat celah riset (*gap*) untuk merancang sebuah model multimodal mandiri yang efisien pada komponen fusi, tidak bergantung pada data eksternal, namun mampu memodelkan interaksi lintas-modalitas secara dinamis. Arsitektur *PhishCross* yang diusulkan dalam penelitian ini hadir untuk mengisi *gap* tersebut. Pada PhishCross, HTML digunakan sebagai *query* asimetris untuk memeriksa fitur URL dan gambar via *cross-attention*. Selain itu, arsitektur ini menerapkan jalur residual (*residual bypass*) untuk mempertahankan informasi HTML langsung ke *classifier head.* Pendekatan ini memungkinkan *PhishCross* untuk memadukan efisiensi komputasi dari pengekstraksi fitur ringan dengan kedinamisan fusi dari model-model besar. Lebih lanjut, penelitian untuk menyaring fitur secara optimal menggunakan algoritma seleksi fitur (Tamal et al., 2024; Zhu et al., 2019) serta integrasi *explainable* AI (XAI) untuk meningkatkan keterbacaan hasil fusi model (Vulfin et al., 2026) terus dikembangkan untuk memperkuat efisiensi dan transparansi sistem deteksi.

C. Kerangka Berpikir

Kerangka berpikir penelitian ini menggambarkan alur sistematis dari identifikasi permasalahan hingga pengujian kelayakan model secara komputasional. Gambar 2.1 memvisualisasikan kerangka berpikir tersebut.



Gambar 2.1 Diagram Alur Kerangka Berpikir Penelitian

Berdasarkan kerangka pemikiran di atas, penelitian ini bertolak dari masalah utama, yakni taktik *evasion* pada serangan *phishing* modern yang tidak lagi memadai jika ditangani oleh arsitektur unimodal, sekaligus tidak efisien jika menggunakan fusi linier statis. Untuk menjawab masalah tersebut, dilakukan pengumpulan data yang bersumber pada dataset publik Phish360

(memuat 10.748 sampel komprehensif) dan ditunjang oleh studi literatur terkait *deep learning* multimodal.

Kedua landasan tersebut bermuara pada tahapan inti metode penelitian yang dieksekusi secara sekuensial:

1. Identifikasi Masalah dan Pemahaman Data

   Memformulasikan tujuan perancangan *PhishCross* dan menganalisis karakteristik *class imbalance* pada dataset.

2. Prapemrosesan Data & Ekstraksi Fitur

   Meliputi pembersihan *tag* HTML non-semantik, pemotongan URL, ekstraksi fitur pra-komputasi menggunakan model *MiniLM* dan *MobileNetV3*, serta pemisahan data dengan *stratified split*.

3. Pemodelan & Pelatihan

   Membangun arsitektur fusi *cross-attention* asimetris dengan *residual bypass*, melatih model menggunakan optimasi *AdamW*, serta menerapkan modality dropout sebesar 15% yang divalidasi secara iteratif per *epoch* hingga mencapai titik konvergensi *loss* dan *F1-Score* yang stabil.

4. Evaluasi Eksperimental

   Melakukan pengujian klasifikasi *checkpoint* pada *test set* terisolasi guna menganalisis metrik *F1-Score*, *precision*, dan *false positive rate* (FPR) komparatif, serta melakukan *ablation study* untuk menguji ketahanan model.

5. Ekspor

   Langkah pemungkas berupa konversi model *PyTorch* ke format ONNX guna memvalidasi efisiensi komputasional dan kelayakan proteksi *client-side*.

D. Hipotesis Penelitian

Berdasarkan rumusan masalah, kajian teori, dan kerangka berpikir yang diajukan, pengujian hipotesis direksional dalam penelitian ini dirumuskan ke dalam pasangan Hipotesis Nol (H_0) dan Hipotesis Alternatif (H_1) sebagai berikut:

1. Pengujian Efektivitas Arsitektur Fusi Multimodal

    a. H_{01}: Arsitektur fusi *cross-attention* asimetris *PhishCross* menghasilkan tingkat *precision* yang sama atau lebih rendah, atau rasio pemblokiran salah (*False Positive Rate*/FPR) yang sama atau lebih tinggi dibandingkan dengan baseline fusi *concatenation* dan *additive attention* pada dataset Phish360.

    b. H_{11}: Arsitektur fusi *cross-attention* asimetris *PhishCross* menghasilkan tingkat *precision* yang lebih tinggi dan rasio pemblokiran salah (*False Positive Rate*/FPR) yang lebih rendah dibandingkan dengan baseline fusi *concatenation* dan *additive attention* pada dataset Phish360.

2. Pengujian Dampak Regularisasi *Modality Dropout*

    a. H_{02}: Penerapan *modality dropout* sebesar 15% pada arsitektur *cross-attention* asimetris bersikuens pendek ($K/V = 2$) meningkatkan *F1-Score* rata-rata *PhishCross* kurang dari 0,5 poin persentase, atau justru memperbesar deviasi standar performa antar-*seed* dibandingkan kondisi tanpa *modality dropout*.

    b. H_{12}: Penerapan *modality dropout* sebesar 15% pada arsitektur *cross-attention* asimetris bersikuens pendek ($K/V = 2$) meningkatkan *F1-Score* rata-rata *PhishCross* minimal 0,5 poin persentase dibandingkan kondisi tanpa *modality dropout*, tanpa memperbesar deviasi standar performa antar-*seed* dibandingkan kondisi tanpa *modality dropout*.

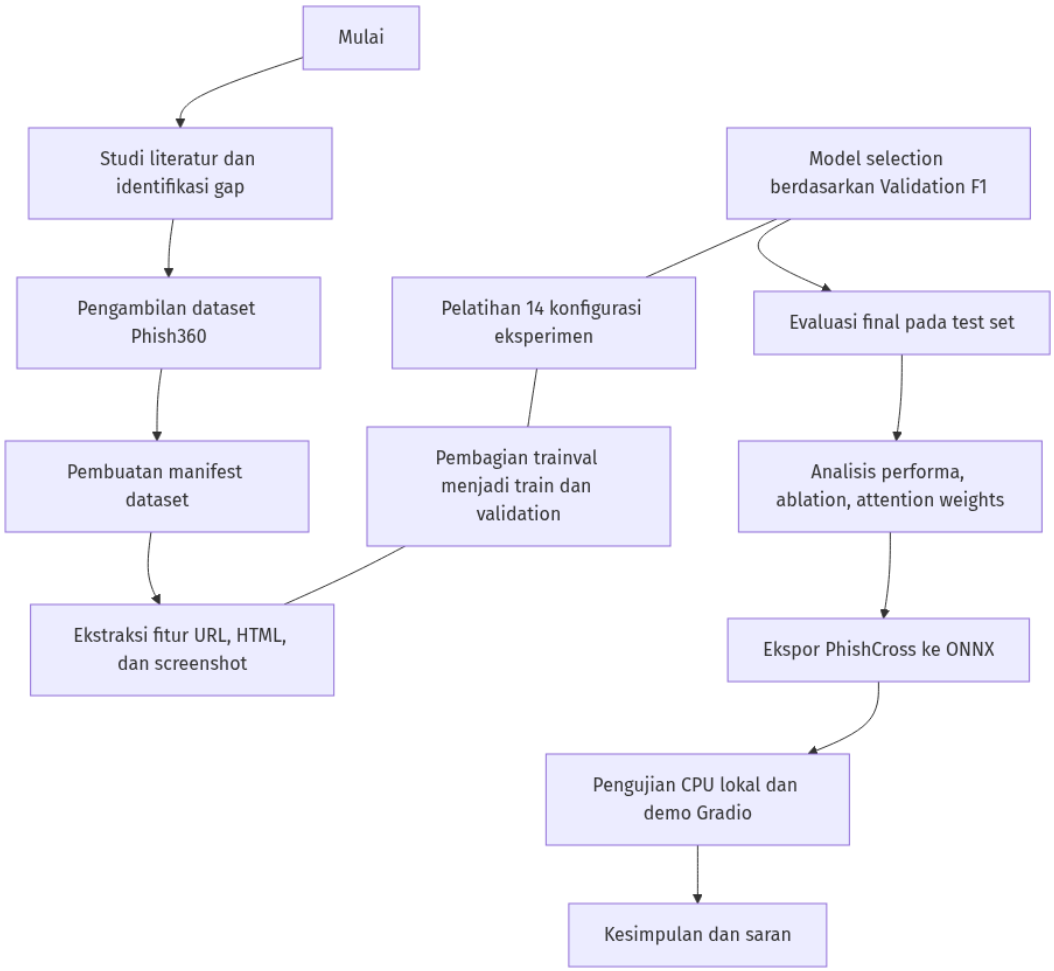
3. Pengujian *Robustness* terhadap Skenario *Missing Modality*

   a. H_{03}: Model *PhishCross* memiliki *robustness* performa absolut yang sama atau lebih buruk (degradasi *F1-Score* yang sama atau lebih besar) secara terukur dibandingkan dengan model *additive attention fusion* saat dievaluasi pada skenario hilangnya salah satu modalitas masukan (URL atau gambar *screenshot*) pada fase inferensi.

   b. H_{13} : Model *PhishCross* memiliki *robustness* performa absolut yang lebih baik (degradasi *F1-Score* yang lebih kecil) secara terukur dibandingkan dengan model *additive attention fusion* saat dievaluasi pada skenario hilangnya salah satu modalitas masukan (URL atau gambar *screenshot*) pada fase inferensi.

BAB III
METODOLOGI PENELITIAN

Bab ini menguraikan tahapan dan prosedur metodologis yang digunakan untuk merancang, melatih, dan mengevaluasi arsitektur *PhishCross*. Struktur pembahasan diatur secara sistematis dimulai dari jenis penelitian, waktu dan tempat pelaksanaan, karakteristik dataset Phish360, spesifikasi perangkat keras dan lunak yang digunakan, hingga detail desain arsitektur model dan metrik evaluasi yang diterapkan. Untuk memberikan gambaran menyeluruh mengenai tahapan pelaksanaan penelitian, alur kerja sistematis disajikan pada Gambar 3.1 berikut.



Gambar 3.1 Alur Penelitian

A. Jenis dan Pendekatan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif eksperimental yang berada pada irisan disiplin *cybersecurity* dan *deep learning*. Secara lebih spesifik, eksperimen ini mengeksplorasi arsitektur fusi multimodal yang mengintegrasikan teknik *natural language processing* dan *computer vision*. Metode eksperimental diterapkan untuk merancang, membangun, dan mengevaluasi kinerja arsitektur model fusi baru yang diusulkan, yaitu *PhishCross*. Melalui pendekatan ini, variabel independen dimanipulasi secara sistematis, yang meliputi variasi metode fusi multimodal (X_1) dan penerapan regularisasi *modality dropout* (X_2). Manipulasi tersebut dilakukan guna mengukur pengaruhnya secara empiris terhadap variabel dependen, yakni kinerja klasifikasi yang diukur melalui metrik *precision*, *false positive rate* (FPR), dan *F1-Score* (Y_1); *robustness* model ketika dihadapkan pada skenario kehilangan modalitas (Y_2); serta efisiensi komputasi yang ditinjau dari ukuran parameter dan latensi inferensi di sisi pengguna (Y_3)(Ali & Rezvani, 2026).

B. Waktu dan Tempat Penelitian

Penelitian ini dilaksanakan secara intensif pada bulan Juni 2026. Proses pemodelan, pelatihan, dan validasi eksperimental dijalankan secara daring memanfaatkan infrastruktur komputasi *cloud Kaggle Notebooks*. Sementara itu, proses konversi model ke format ONNX dan pengujian latensi CPU lokal dilakukan secara mandiri pada lingkungan komputasi lokal peneliti.

C. Dataset dan Pembagian Data

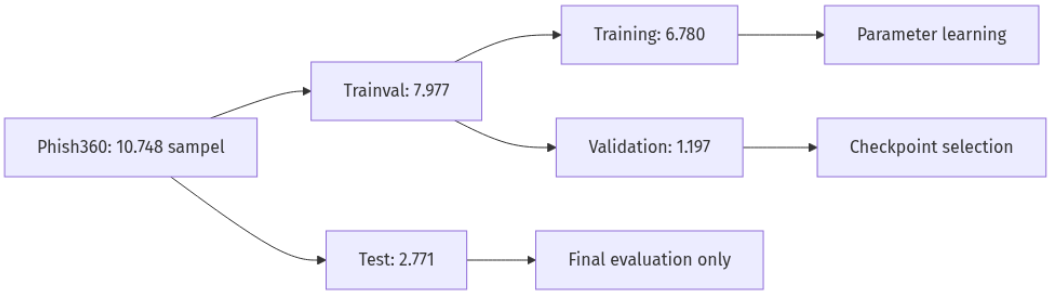
Penelitian ini menggunakan dataset Phish360, sebuah dataset multimodal publik *anti-phishing* pada kondisi aktual yang dipublikasikan oleh (Almakhamreh & Bozkir, (2026b) yang terdiri dari 10.748 sampel. Setiap sampel di dalam dataset ini merupakan representasi lengkap dari suatu situs web yang memuat tiga modalitas masukan yaitu alamat situs (URL), teks yang terlihat pada kode sumber (HTML), dan citra tangkapan layar visual (*screenshot*) (Almakhamreh & Bozkir, 2026a).

Dalam eksperimen ini, dataset dibagi menjadi tiga bagian terpisah yaitu *training*, *validation*, dan *test set*. Dataset Phish360 menyediakan pemisahan awal berupa kelompok data gabungan trainval dan data pengujian test (Almakhamreh & Bozkir, 2026b). Peneliti membagi data trainval secara internal menjadi *training* dan *validation* menggunakan rasio 85:15 berbasis strategi *stratified split* untuk menjaga proporsi distribusi kelas target yang seimbang pada kedua subset. Pembagian subset trainval menjadi *training* (85%) dan *validation* (15%), dilakukan secara dinamis untuk setiap iterasi pengujian menggunakan parameter `random_state` yang diikat pada nilai *seed* eksperimen masing-masing. Sementara itu, *test set* dipertahankan konstan di seluruh konfigurasi eksperimen guna menjamin komparabilitas performa langsung. Penggunaan subset validasi internal ini krusial untuk mencegah kebocoran data (*data leakage*). Hal ini dikarenakan, subset validasi digunakan sebagai satu-satunya acuan dalam mekanisme *early stopping* dan pemilihan *checkpoint* model terbaik. Disisi lain *test set* dipertahankan dalam kondisi terisolasi untuk evaluasi final.

Perlu dicatat bahwa Phish360 merupakan dataset statis, bukan aliran URL *phishing* yang baru dilaporkan secara *real-time*. Oleh karena itu, dataset ini belum sepenuhnya merepresentasikan skenario *zero-day phishing* atau *early-stage phishing* dalam 24-72 jam pertama sejak URL berbahaya muncul. Keterbatasan ini dipertimbangkan dalam pembahasan validitas eksternal penelitian.

Tabel 3.1 Skema Pembagian Dataset Phish360

Split	***Legitimate*(0)**	***Phishing*(1)**	**Total**	**Kegunaan**
Training	4.179	2.601	6.780	Melatih parameter model
Validation	738	459	1.197	Memilih *checkpoint* terbaik
Test	1.499	1.272	2.771	Evaluasi final terisolasi
Total	**6.416**	**4.332**	**10.748**	**Seluruh Data**



Gambar 3.2 Skema Pembagian Dataset

Berdasarkan skema pembagian tersebut, terdapat perbedaan proporsi distribusi kelas yang kecil antara data *training* (61,6% *legitimate*) dan data *test* (54,1% *legitimate*). Kondisi ini dipertahankan apa adanya karena merupakan karakteristik bawaan dari pembagian asli dataset Phish360 guna mensimulasikan *class imbalance* pada kondisi aktual secara objektif tanpa manipulasi buatan pada data uji (Almakhamreh & Bozkir, 2026b).

D. Spesifikasi Perangkat Keras dan Perangkat Lunak

Untuk menjamin reprodusibilitas eksperimen, penelitian ini merinci spesifikasi lingkungan kerja perangkat keras (*hardware*) dan perangkat lunak (*software)* sebagai berikut:

1. Perangkat Keras:

   a. Infrastruktur Pelatihan (*Cloud*)

   Kaggle Notebook dengan alokasi GPU T4 x2, yakni dua akselerator grafis *Nvidia Tesla* T4. Pada konfigurasi ini GPU 2 didelegasikan untuk prapemrosesan dan pra-komputasi ekstraksi fitur modalitas (*feature precomputation*), sedangkan GPU 1 dialokasikan khusus untuk proses pelatihan model klasifikasi utama.

   b. Infrastruktur Pengujian Latensi (Lokal CPU)

   Laptop Asus TUF Gaming F15 FX506LHB, Intel(R) Core(TM) i5-10300 CPU @ 2,50 GHz, RAM 8 GB, dengan sistem operasi Windows 11.

2. Perangkat Lunak:

   a. Bahasa Pemrograman

      Python 3.11

   b. Pustaka Utama *Deep Learning*

      PyTorch untuk pendefinisian model dan estimasi bobot gradien.

   c. Pustaka Runtime Lokal

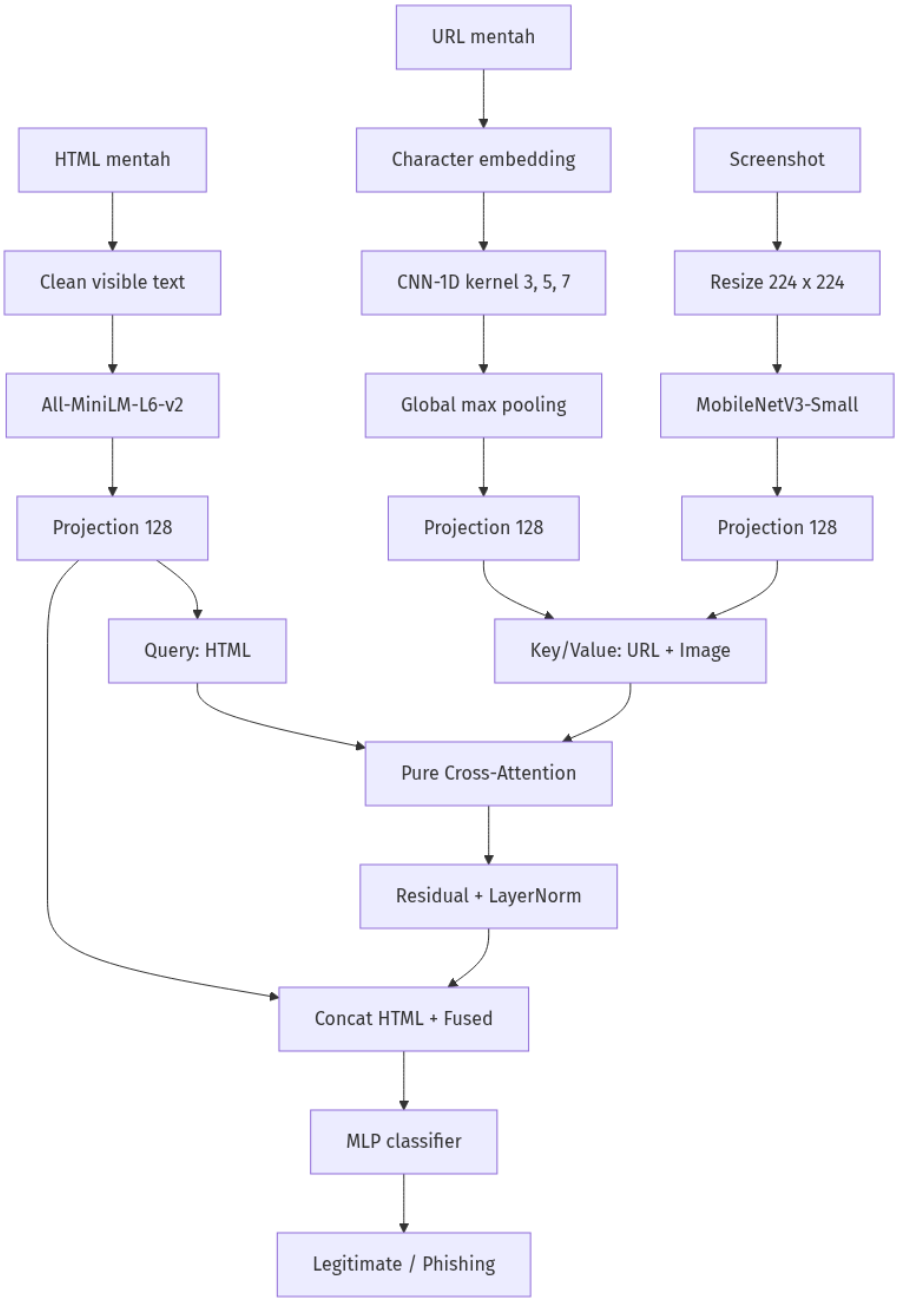
      ONNX *runtime* (CPU *version*) untuk evaluasi performa model teroptimasi.

   d. Instrumen Prapemrosesan

      BeautifulSoup4 untuk ekstraksi dan pembersihan teks dinamis dokumen HTML.

E. Teknik Analisis Data

1. Arsitektur Model *PhishCross*



Gambar 3.3 Arsitektur Model *PhishCross*

Arsitektur model *PhishCross* dirancang secara khusus untuk menggabungkan representasi dari tiga modalitas masukan secara asimetris. Model ini terdiri atas empat komponen utama yang bekerja secara sekuensial yang dipaparkan pada subbab berikut ini.

a. URL Character-level CNN Encoder

URL diproses pada tingkat karakter secara langsung tanpa memerlukan segmentasi tingkat kata (*vocabulary-free*) (Butnaru et al., 2021). Setiap karakter di dalam URL tersebut dipetakan menjadi vektor representasi berdimensi 48 melalui *embedding layer* yang memiliki kapasitas 87 karakter unik. Karakter ini mencakup huruf kecil, huruf kapital, digit angka, karakter khusus URL, serta token khusus untuk pengisi (*padding*) dan karakter tak dikenal (*unknown)*. Untuk menyeragamkan dimensi masukan, panjang maksimal input URL dibatasi hingga 256 karakter melalui proses pemotongan (*truncation*) atau penambahan (*padding*) dinamis (Asiri et al., 2024).

Representasi matriks karakter tersebut kemudian dialirkan ke dalam tiga filter konvolusi satu dimensi (CNN-1D) paralel dengan variasi ukuran kernel 3, 5, dan 7. Masing-masing filter konvolusi menghasilkan 128 *feature maps* (Butnaru et al., 2021). Pemilihan variasi kernel ini bertujuan menangkap pola urutan karakter pada berbagai skala n-gram, seperti pola trigram untuk mengenali nama domain hingga heptagram untuk mendeteksi anomali kata kunci mencurigakan pada bagian direktori.

Output dari ketiga filter tersebut digabungkan melintasi dimensi fitur melalui *global max pooling*. Operasai ini secara spesifik dipilih guna menyaring keberadaan fitur diagnostik terkuat terlepas dari posisinya pada sekuens URL, yang pada akhirnya menghasilkan vektor gabungan berdimensi 384. Vektor ini kemudian diproyeksikan ke dimensi 128 melalui *fully connected layer* dengan aktivasi ReLU dan *dropout* 0,35 (Asiri et al., 2024; Rao et al., 2025).

Berbeda dengan *encoder* HTML dan visual yang parameter bobotnya dibekukan (*frozen*), modul URL Char-CNN ini dilatih dari awal (*end-to-end trainable*) karena tidak tersedia model pra-latih komprehensif untuk representasi karakter URL yang bersifat spesifik-domain (*domain-specific*). Perbedaan pendekatan pelatihan ini menyiratkan bahwa performa *encoder* URL berpotensi terus meningkat seiring bertambahnya variasi data pelatihan di masa mendatang, sementara kapasitas representasi *encoder* HTML dan visual yang dibekukan sudah berada pada kapasitas representasi semantik dan spasialnya yang stabil.

b. HTML Semantic Encoder

Informasi semantik dari kode marka HTML diekstraksi menggunakan model bahasa pra-latih *all-MiniLM-L6-v2* yang efisien (W. Wang et al., 2020). Sebelum pemrosesan, dokumen HTML dibersihkan dari tag non-semantik (seperti tag `<script>`, `<style>`, dan `<noscript>`) menggunakan *BeautifulSoup*. Teks yang tersisa dinormalisasi dari spasi berlebih dan dipotong hingga batas maksimal 4.000 karakter (Yoon et al., 2024). Model *MiniLM* memproses teks bersih tersebut dan menghasilkan vektor semantik berdimensi 384. Vektor ini diproyeksikan ke dimensi 128 menggunakan lapisan linear dengan aktivasi ReLU dan *dropout* 0,35 (W. Wang et al., 2020). Untuk menekan waktu latih eksperimen, vektor fitur HTML diekstraksi terlebih dahulu (*precompute*) dan disimpan dalam format berkas *NumPy* (.npy). Proses ini dilakukan secara independen untuk setiap sampel menggunakan *encoder* beku, sehingga tidak menghitung statistik global dari gabungan *training*, *validation*, dan *test set*.

c. Visual Feature Extractor

Fitur visual dari gambar tangkapan layar situs web diekstraksi menggunakan model *computer vision MobileNetV3-Small*. Arsitektur ini dipilih karena memiliki rancangan yang sangat ringan, namun tetap

tangguh dalam menangkap fitur visual komprehensif yang relevan (Azhar et al., 2026; Howard et al., 2019). Selama eksperimen, bobot parameter model ini sengaja dibekukan (*frozen pre-trained*) untuk menjamin stabilitas representasi visual yang konsisten di seluruh variasi model fusi yang diuji.

Sebelum diproses, setiap gambar *screenshot* diubah ukurannya (*resize*) menjadi resolusi standar 224 x 224 piksel. Proses normalisasi citra sepenuhnya menggunakan konstanta bawaan dari *ImageNet*, bukan statistik yang dihitung ulang dari dataset Phish360. Pendekatan ini sangat krusial untuk *data leakage*, yakni memastikan agar tahap ekstraksi tidak menyerap atau memasukkan informasi label maupun distribusi data uji ke dalam proses pelatihan. Selain itu, tidak ada teknik augmentasi spasial seperti rotasi atau distorsi warna, yang diterapkan pada gambar, mengingat model digunakan murni sebagai pengekstraksi visual statis.

Proses ekstraksi dilakukan dengan mengambil keluaran aktivasi dari lapisan *average pooling* terakhir model, yang menghasilkan vektor representasi berdimensi 576. Vektor mentah ini kemudian diproyeksikan ke dimensi sasaran 128. Guna memaksimalkan efisiensi waktu komputasi, fitur visual terproyeksi ini diekstraksi dan disimpan ke dalam media penyimpanan (*precompute*) secara mandiri sebelum tahap pelatihan utama klasifikasi dimulai.

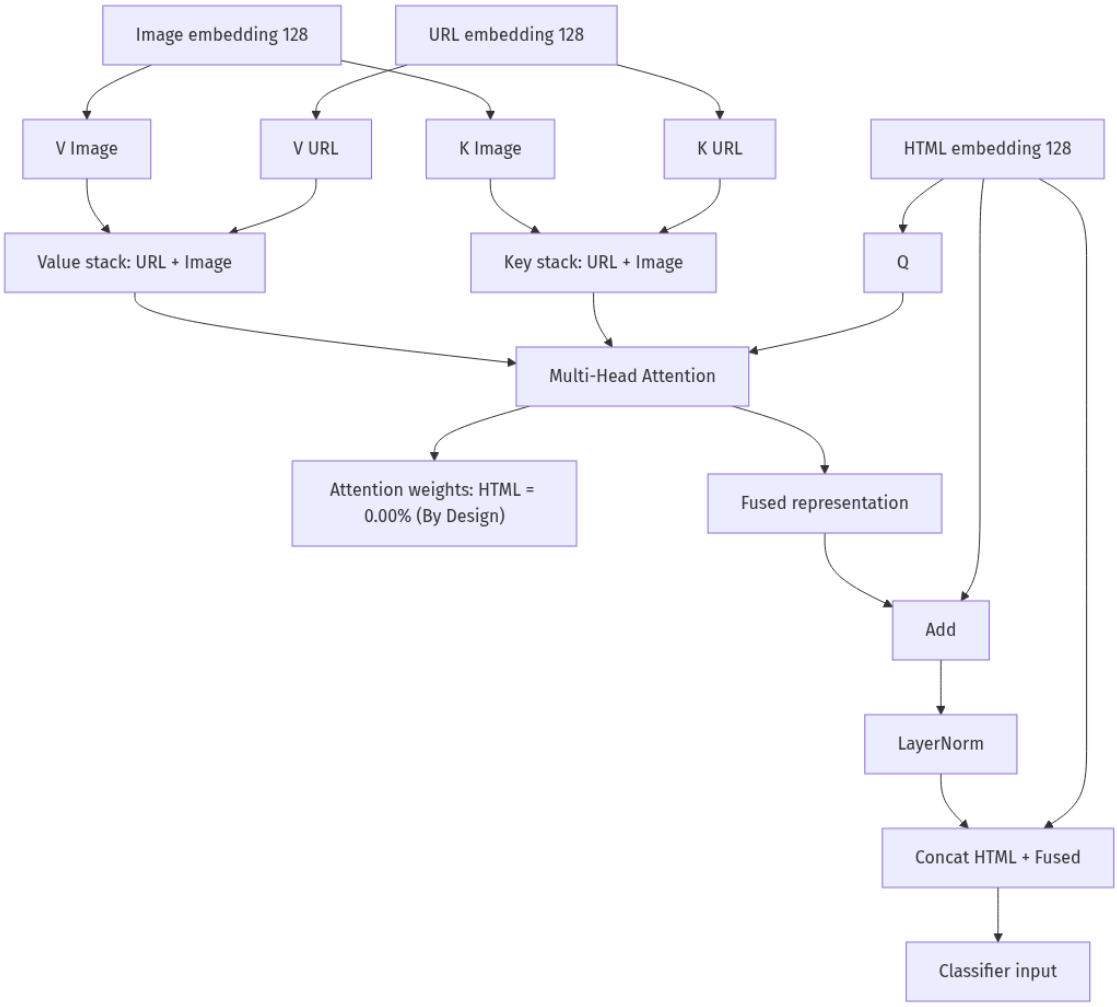
d. Cross-Attention Fusion Layer

Komponen inti *PhishCross* adalah mekanisme *cross-attention fusion* asimetris (Lu et al., 2019). Berbeda dari fusi linier statis, mekanisme ini memosisikan representasi semantik HTML sebagai *query* ($Q \in \mathbb{R}^{1\times d}$), sedangkan representasi URL dan representasi visual digabungkan secara vertikal (*stacking*) untuk bertindak sebagai key ($K \in \mathbb{R}^{2\times d}$) dan value ($V \in \mathbb{R}^{2\times d}$), dengan dimensi proyeksi $d = 128$. Formulasi aljabar mekanisme ini didefinisikan sebagai:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (12)$$

Mekanisme ini menggunakan *Multi-Head Attention* dengan 4 *head* paralel (Vaswani et al., 2017). Pada konfigurasi ini, dimensi proyeksi internal untuk masing-masing *head* (d_k) adalah 32 ($d_k = d/\text{num_heads} = 128/4 = 32$). Walaupun panjang sekuens kunci/nilai (K dan V) sangat pendek (hanya berisi 2 vektor modalitas yaitu URL dan gambar, yang menjadi batasan inheren representasi sekuens pendek model ini), penggunaan 4 *head* tetap dipertahankan. Konfigurasi ini memfasilitasi model untuk memproyeksikan fitur multimodal ke dalam beberapa subruang representasi (*subspaces*) yang berbeda secara bersamaan sebelum diintegrasikan kembali.

Sebagai landasan konseptual dari sifat asimetrisnya, HTML sengaja diabsenkan dari tumpukan *key-value stack* agar interaksi atensi hanya terjadi satu arah, yakni dari HTML menuju modalitas pendukung. Dalam skema ini, representasi fitur HTML digunakan murni sebagai *query* (Q) untuk mengekstraksi informasi relasional dari URL dan visual *screenshot* melalui operasi *cross-attention*, tanpa melibatkan *self-attention* terhadap dirinya sendiri (Lu et al., 2019; X. Wang et al., 2025). Meskipun diabsenkan dari matriks nilai, kelengkapan informasi semantik HTML dipastikan tidak hilang karena ia tetap dialirkan melalui *residual bypass* menuju *classifier head*. Serangkaian keputusan desain inilah yang mendasari definisi *PhishCross* sebagai arsitektur *"HTML-queried cross-attention with residual bypass"*.



Gambar 3.4 Detail Pure Cross-Attention

Output dari operasi *cross-attention* ($\hat{h}$) digabungkan dengan representasi HTML asli menggunakan koneksi sisa (*residual connection*) diikuti oleh lapisan normalisasi (*layer normalization*) untuk mencegah masalah gradien hilang (Vaswani et al., 2017):

$$\hat{h}_{\text{fused}} = \text{LayerNorm}(h_{\text{html}} + \hat{h})$$

Vektor fusi akhir dibentuk dengan menggabungkan representasi HTML asli dan output fusi terlapisi secara langsung: $[h_{\text{html}}; \hat{h}_{\text{fused}}] \in \mathbb{R}^{256}$. Vektor ini kemudian dialirkan ke *multi-layer perceptron* (MLP) *classifier head* dengan struktur 256-256-ReLU-*dropout*-2 untuk menghasilkan probabilitas klasifikasi akhir.

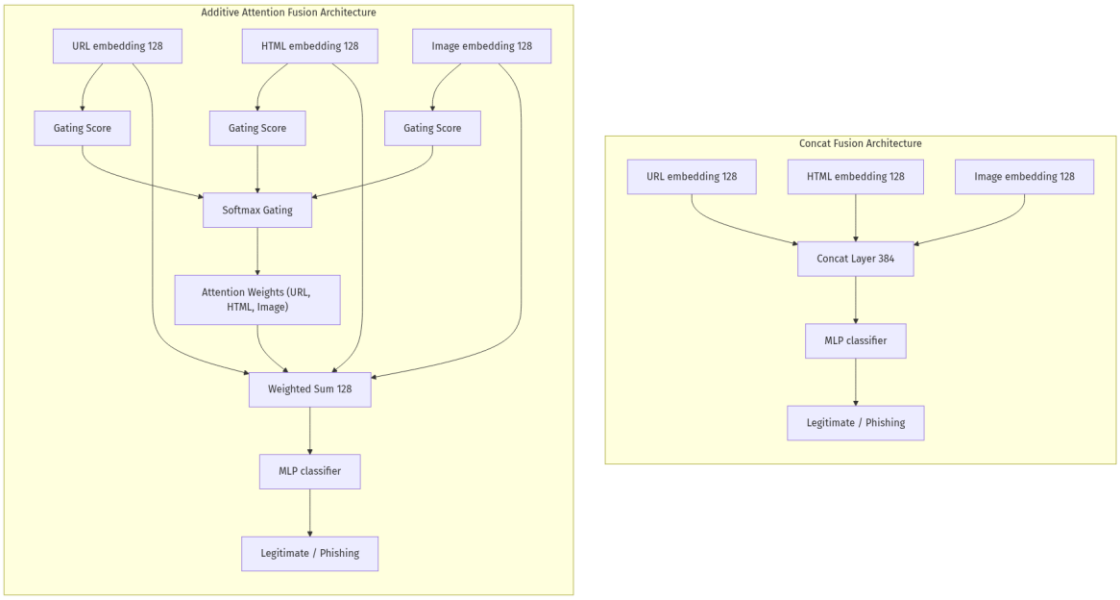
e. Modality Dropout

Guna mencegah model mengalami ketergantungan berlebih pada satu modalitas tertentu *PhishCross* menerapkan strategi regularisasi *modality dropout* (R. Lin & Hu, 2023). Selama fase *forward pass* di pelatihan, setiap representasi modalitas masukan baik URL, HTML, maupun visual scrnshot, memiliki probabilitas 15% untuk di-*zero-out* (nilainya digantikan dengan vektor nol).

Penetapan probabilitas 15% ini dilandasi oleh serangkaian analisis awal yang membandingkannya dengan dua nilai ambang ekstrem, yakni $p = 5\%$ dan $p = 30\%$. Berdasarkan hasil observasi, penggunaan probabilitas rendah ($p = 5\%$) gagal memberikan efek regularisasi yang cukup, sehingga model tetap kurang tangguh saat dihadapkan pada skenario *missing modality* di fase validasi. Sebaliknya, penggunaan probabilitas yang terlalu tinggi ($p = 30\%$) justru memicu divergensi *loss* secara konsisten semenjak *epoch* ketiga.

Ketidakstabilan ekstrem pada tingkat *dropout* yang tinggi tersebut berakar dari frekuensi stokastik; di mana kedua modalitas kunci (URL dan visual *screenshot*) memiliki risiko sangat besar untuk dilumpuhkan secara bersamaan dalam satu iterasi. Kondisi ini memaksa model menerima sinyal gradien yang sangat tidak konsisten antar-*batch* (stokastisitas gradien tinggi), yang pada akhirnya menggagalkan konvergensi model (R. Lin & Hu, 2023; Srivastava et al., 2014). Oleh karena itu, probabilitas 15% ditetapkan sebagai titik moderat yang paling optimal untuk menjaga keseimbangan antara ketahanan model dan stabilitas pelatihan.

f. Arsitektur Model Pembanding



Gambar 3.5 Arsitektur Model Pembanding

Untuk menguji kontribusi arsitektur *PhishCross* secara objektif, model dibandingkan dengan dua metode fusi multimodal konvensional (Almakhamreh & Bozkir, 2026a):

1) Concat (Concatenation Fusion)

Model fusi paling sederhana yang menggabungkan vektor fitur URL (128), HTML (128), dan visual (128) secara langsung tanpa interaksi lintas-fitur: $[h_{\text{url}}; h_{\text{html}}; h_{\text{image}}] \in \mathbb{R}^{384}$ (Almakhamreh & Bozkir, 2026a). Vektor ini dialirkan ke MLP berukuran 384-256-ReLU-*dropout*-2.

2) Attention (Additive Attention Fusion)

Model fusi aditif simetris di mana setiap fitur modalitas diproyeksikan ke skor kepentingannya secara dinamis (Luong et al., 2015). Skor tersebut dinormalisasi dengan *softmax* menghasilkan bobot perhatian ($w_{\text{url}}, w_{\text{html}}, w_{\text{image}}$) dengan jumlah total 1. Vektor fusi diperoleh dari penjumlahan berbobot:

$$h_{\text{fused}} = w_{\text{url}} h_{\text{url}} + w_{\text{html}} h_{\text{html}} + w_{\text{image}} h_{\text{image}}$$

Vektor fusi $h_{\text{fused}} \in \mathbb{R}^{128}$ ini kemudian dialirkan ke MLP *classifier* berukuran 128-256-ReLU-*dropout*-2. Mekanisme ini menjelaskan secara alamiah mengapa arsitektur *attention* kelak memproyeksikan distribusi bobot secara simetris untuk ketiga modalitas masukannya, berbeda dengan *PhishCross* yang menggunakan *cross-attention* asimetris berbasis *query-key value* dan *residual bypass* HTML.

2. Strategi *Training*

Pelatihan model dijalankan dengan mengunggah modul *Python* dari paket *phishcross* ke *Kaggle Notebook*, yang berperan sebagai *orchestrator* untuk memanggil rutin ekstraksi fitur dan pelatihan 14 konfigurasi eksperimen.

a. *Optimizer* dan *Hyperparameter*

Setiap konfigurasi eksperimen dilatih menggunakan parameter kontrol yang ketat untuk memastikan keadilan evaluasi komparatif.

Tabel 3.2 Parameter dan *Hyperparameter* Pelatihan

Parameter	Nilai	Keterangan
Optimizer	AdamW	Adam dengan *decoupled weight decay*
Learning rate awal	$\mathbf{1 \times 10^{-3}}$	Kecepatan penyesuaian bobot awal
Weight decay	$\mathbf{1 \times 10^{-3}}$	Koefisien regularisasi L2
Batch size	64	Jumlah sampel per iterasi
Maksimal *epoch*	30	Batas atas iterasi pelatihan
Loss function	*CrossEntropyLoss*	Fungsi kerugian klasifikasi biner
Random seed	42, 43, 44	Tiga inisialisasi berbeda yang diuji

Modality dropout	15%	Probabilitas pelumpuhan modalitas

Untuk menangani *class imbalance* pada subset data latihan, diimplementasikan *WeightedRandomSampler* pada data *loader PyTorch* (Omari & Oukhatar, 2025), sehingga kelas minoritas (*phishing*) memiliki probabilitas pemilihan yang lebih tinggi pada pembentukan setiap *batch* latih. Bobot sampel dihitung ulang dari distribusi label subset *training* pada setiap *run*, bukan dari subset validasi atau *test set*.

Pemilihan hyperparameter dilakukan melalui pencarian grid terbatas (*limited grid search*) karena adanya batasan waktu komputasi *Kaggle*. Nilai *modality dropout* 15% dipilih dari pembandingan awal terhadap 5% dan 30%, sedangkan jumlah *attention heads* (4), learning rate 1×10^{-3}, dan konfigurasi dimensi proyeksi dipertahankan konstan agar seluruh eksperimen memiliki protokol pembanding yang sama. Studi lebih luas terhadap *learning rate*, jumlah *attention heads* (misalnya 2 atau 8), dan rentang *dropout* yang lebih rapat diposisikan sebagai agenda penelitian lanjutan.

Penggunaan *seed* berurutan (42, 43, 44) juga merupakan keterbatasan desain replikasi. Walaupun ketiga *seed* tersebut menghasilkan inisialisasi berbeda dan cukup untuk analisis variansi awal, penelitian lanjutan disarankan memakai *seed* acak non-berurutan (misalnya 7, 42, 137, dan seterusnya) agar ruang variasi inisialisasi yang dieksplorasi lebih luas.

b. *Learning Rate Scheduler*

Kecepatan belajar diturunkan secara dinamis mengikuti fungsi *cosinus* dari nilai maksimum awal 1×10^{-3} hingga batas minimum 1×10^{-6} menggunakan *CosineAnnealingLR*:

$$\text{Learning Rate}_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min})\left(1+\cos\left(\frac{t}{T_{max}}\pi\right)\right) \quad (13)$$

di mana $T_{max} = 30$ epoch, $\eta_{max} = 10^{-3}$, dan $\eta_{min} = 10^{-6}$.

c. *Early Stopping* dan *Model Selection*

Pelatihan diawasi oleh mekanisme *early stopping* dengan batas toleransi (*patience*) sebesar 7 *epoch* (Rao et al., 2025). Jika metrik *F1-Score* pada subset validasi tidak mengalami peningkatan selama 7 *epoch* berturut-turut, maka pelatihan dihentikan. *Checkpoint model* terbaik disimpan berdasarkan pencapaian *F1-Score* tertinggi pada subset validasi, yang kemudian dimuat kembali untuk dievaluasi satu kali pada *test set* terisolasi.

Karena subset validasi juga digunakan untuk memilih *checkpoint* dan menjadi rujukan dalam pencarian hyperparameter terbatas, hasil validasi tidak diperlakukan sebagai estimasi performa akhir yang bebas bias. Estimasi performa utama tetap didasarkan pada *test set* terisolasi. Sementara itu, risiko optimisme akibat penggunaan validasi berulang dicatat sebagai keterbatasan penelitian.

3. Desain Eksperimen

Evaluasi performa model dilakukan terhadap 14 konfigurasi eksperimen yang dikelompokkan ke dalam tiga kategori pengujian (Almakhamreh & Bozkir, 2026a):

a. Kategori 1

Single modality (E1–E3): Mengevaluasi kekuatan klasifikasi masing-masing modalitas secara terpisah (`url_only`, html_only, dan `image_only`).

b. Kategori 2

Multi-modal fusion (E4–E6): Membandingkan model fusi penuh yang menggunakan ketiga modalitas (*concat*, *attention*, dan *phishcross*).

c. Kategori 3

Ablation Study (E7–E14):

1) E7-E9: Menghapus satu modalitas dari model *attention*.

2) E10-E12: Menghapus satu modalitas dari model *PhishCross*.

3) E13-E14: Menonaktifkan *modality dropout* (diset ke 0%) pada model *attention* dan *PhishCross* untuk melihat dampaknya terhadap stabilitas pelatihan (R. Lin & Hu, 2023).

Secara komprehensif, seluruh empat belas konfigurasi eksperimen tersebut dirangkum pada Tabel 3.3 di bawah ini.

Tabel 3.3 Pemetaan 14 Konfigurasi Eksperimen

Kode	**Nama Eksperimen**	**Modalitas**	***Modality Dropout***	**Kategori**
E1	url_only	URL	N/A	*Single modality*
E2	html_only	HTML	N/A	*Single modality*
E3	image_only	Image	N/A	*Single modality*
E4	concat	URL+HTML+Img	15%	Fusi multimodal

Kode	**Nama Eksperimen**	**Modalitas**	***Modality Dropout***	**Kategori**
E5	*attention*	URL+HTML+Img	15%	Fusi multimodal
E6	phishcross	URL+HTML+Img	15%	Fusi multimodal
E7	attention_no_url	HTML+Img	15%	*Ablasi attention*
E8	attention_no_html	URL+Img	15%	*Ablasi attention*
E9	attention_no_image	URL+HTML	15%	*Ablasi attention*
E10	phishcross_no_url	HTML+Img	15%	*Ablasi PhishCross*
E11	phishcross_no_html	URL+Img	15%	*Ablasi PhishCross*
E12	phishcross_no_image	URL+HTML	15%	*Ablasi PhishCross*
E13	attention_no_moddrop	URL+HTML+Img	0%	Kontrol *dropout*
E14	phishcross_no_moddrop	URL+HTML+Img	0%	Kontrol *dropout*

4. Pengujian Efisiensi dan Konversi ONNX

Klaim efisiensi model diverifikasi melalui dua tahap pengujian komputasi (Roy & Nilizadeh, 2026). Pertama, pencatatan waktu inferensi

dilakukan saat evaluasi *test set* untuk mengukur waktu *forward pass classifier head* setelah fitur representasi URL, HTML, dan gambar tersedia.

Kedua, *checkpoint* terbaik dari model *PhishCross* diekspor ke format *open neural network exchange* (ONNX) dengan versi opset 18 menggunakan input *dummy* berdimensi aktual (Roy & Nilizadeh, 2026) yang meliputi URL sepanjang 256 token, fitur HTML berdimensi 384, dan fitur visual berdimensi 576. Output logits dan bobot perhatian dari berkas ekspor `phishcross_optimized.onnx` divalidasi silang secara ketat dengan model *PyTorch* asli untuk memastikan konsistensi numerik. Pengujian latensi ONNX lokal dilakukan pada CPU laptop *Asus TUF Gaming* selama 1.000 iterasi untuk mencatat rata-rata latensi, median (P50), P95, dan *throughput* komputasi.

5. Metrik Evaluasi

Parameter utama yang dijadikan landasan evaluasi diekstraksi menggunakan instrumen *confusion matrix*, yang kemudian diturunkan menjadi perhitungan metrik sebagai berikut (Almakhamreh & Bozkir, 2026a):

Tabel 3.4 Matriks Metrik Evaluasi Kinerja Model

Metrik	Deskripsi Tujuan	Formulasi Matematis
Accuracy	Mengukur proporsi prediksi benar secara keseluruhan	$\frac{TP + TN}{TP + TN + FP + FN}$
Precision	Mengukur ketepatan prediksi phishing (meminimalkan FP)	$\frac{TP}{TP + FP}$
Recall	Mengukur cakupan deteksi halaman phishing (meminimalkan FN)	$\frac{TP}{TP + FN}$
F1-Score	Rata-rata harmonik penyeimbang presisi dan recall	$\frac{2 \cdot P \cdot R}{P + R}$

ROC-AUC	Mengukur kemampuan deskriminasi model lintas-threshold	Area dibawah kurva ROC
PR-AUC	Area dibawah kurva precision-recall (mengukur kinerja pada data tidak seimbang)	$\int_0^1 \boldsymbol{P}(\boldsymbol{R})\, \boldsymbol{dR}$
FPR	Mengukur rasio halaman sah yang salah diblokir	$\frac{\boldsymbol{FP}}{\boldsymbol{FP}+\boldsymbol{TN}}$
FNR	Mengukur rasio halaman phishing yang lolos deteksi	$\frac{\boldsymbol{FN}}{\boldsymbol{FN}+\boldsymbol{TP}}$
Latency	Mengukur kecepatan inferensi komputasi classifier	Waktu forward pass per sampel

Selain metrik di atas, bobot perhatian (*attention weights*) dianalisis untuk membaca pola mekanisme fusi internal model secara deskriptif tanpa mengasumsikannya sebagai hubungan kausal mutlak dari kontribusi fitur (Jain & Wallace, 2019).

Untuk validasi statistik komparatif antar-model pada data uji yang sama, penelitian ini menambahkan uji *McNemar* pasca-inferensi. Uji ini dilakukan tanpa pelatihan ulang, melainkan dengan memuat kembali *checkpoint* final setiap model dan menjalankan inferensi ulang pada t*est set* yang sama untuk memperoleh prediksi per-sampel. *McNemar* digunakan karena bekerja pada pasangan prediksi benar-salah dari dua model pada sampel identik. Nilai b didefinisikan sebagai jumlah sampel yang diprediksi benar oleh *PhishCross* tetapi salah oleh baseline, sedangkan c adalah jumlah sampel yang salah oleh *PhishCross* tetapi benar oleh baseline. Statistik *McNemar* dengan koreksi kontinuitas dihitung sebagai berikut:

$$\chi^2 = \frac{(|b-c|-1)^2}{b+c} \tag{14}$$

Lebih lanjut, karena jumlah pasangan *discordant* pada beberapa perbandingan tidak terlalu besar, penelitian ini juga melaporkan *exact p-value*

berbasis distribusi binomial dua sisi. Hasil uji ini digunakan sebagai validasi pendukung terhadap klaim komparatif, bukan sebagai satu-satunya dasar penerimaan hipotesis.

6. Kriteria Pengujian Hipotesis

Untuk menghindari interpretasi yang terlalu longgar, pengujian hipotesis pada Bab IV menggunakan kriteria operasional berikut:

a. H_{01} ditolak sehingga H_{11} diterima penuh. Jika *PhishCross* memiliki nilai *precision* lebih tinggi dan FPR lebih rendah daripada *concat* serta *attention* pada rata-rata 3 *seed* dan pada seluruh *seed* individual, serta didukung oleh uji *McNemar* yang konsisten. Jika keunggulan hanya muncul pada rata-rata 3 *seed* dan minimal 2 dari 3 *seed* individual, tetapi tidak konsisten pada uji *McNemar* atau salah satu *seed* individual, hipotesis dinyatakan diterima sebagian.

b. H_{02} ditolak sehingga H_{12} diterima. Jika konfigurasi *PhishCross* dengan *modality dropout* 15% meningkatkan *F1-Score* rata-rata minimal 0,5 poin persentase dibanding konfigurasi tanpa *modality dropout*, serta memiliki standar deviasi performa antar-*seed* yang tidak lebih besar.

c. H_{03} ditolak sehingga H_{13} diterima penuh. Jika *PhishCross* memiliki degradasi *F1-Score* lebih kecil daripada *attention fusion* pada skenario kehilangan URL dan kehilangan gambar. Jika hanya salah satu skenario yang terpenuhi, hipotesis dinyatakan diterima sebagian.

Kriteria di atas digunakan bersama hasil uji *McNemar* sebagai dasar pembacaan hipotesis. Karena eksperimen hanya menggunakan 3 inisialisasi *seed*, hasil pengujian tetap perlu divalidasi lebih lanjut dengan jumlah *seed* yang lebih besar.

DAFTAR PUSTAKA

Abdelnabi, S., Krombholz, K., & Fritz, M. (2020). VisualPhishNet: Zero-Day Phishing Website Detection by Visual Similarity. *Proceedings of the 2020 ACM SIGSAC Conference on Computer and Communications Security*, 1681–1698. https://doi.org/10.1145/3372297.3417233

Ahmad, S., Zaman, M., Sami Al-Shamayleh, A., Ahmad, R., Muhammad Abdulhamid, S., Ergen, I., & Akhunzada, A. (2025). Across the Spectrum In-Depth Review AI-Based Models for Phishing Detection. *IEEE Open Journal of the Communications Society*, *6*, 2065–2089. https://doi.org/10.1109/OJCOMS.2024.3462503

Aksoy, M., Kurt Pehlivanoğlu, M., & Yiğit, H. (2026). Parameter-Efficient Hybrid Architectures for Multimodal Phishing Detection: Insights from the MTLP Dataset. *International Journal of Information Security Science*, *14*(4), 1–12. https://doi.org/10.55859/ijiss.1813327

Ali, A. K., & Rezvani, M. (2026). Optimized and Explainable Multimodal Deep Learning Framework for Accurate Phishing Website Detection. *International Journal of Electronics and Communication Engineering*, *13*(5), 97–108. https://doi.org/10.14445/23488549/IJECE-V13I5P110

Aljofey, A., Jiang, Q., Qu, Q., Huang, M., & Niyigena, J.-P. (2020). An Effective Phishing Detection Model Based on Character Level Convolutional Neural Network from URL. *Electronics*, *9*(9), 1514. https://doi.org/10.3390/electronics9091514

Almakhamreh, A. H. A., & Bozkir, A. S. (2026a). CrossPhire: Benefiting Multimodality for Robust Phishing Web Page Identification. *Applied Sciences*, *16*(2), 751. https://doi.org/10.3390/app16020751

Almakhamreh, A. H. A., & Bozkir, A. S. (2026b). *Phish360: The ultimate multimodal dataset for phishing detection*. https://web.cs.hacettepe.edu.tr/~selman/phish360-dataset/

Alshingiti, Z., Alaqel, R., Al-Muhtadi, J., Haq, Q. E. U., Saleem, K., & Faheem, M. H. (2023). A Deep Learning-Based Phishing Detection System Using CNN, LSTM, and LSTM-CNN. *Electronics*, *12*(1), 232. https://doi.org/10.3390/electronics12010232

Anti-Phishing Working Group. (2024). *Phishing Activity Trends Report: 4th Quarter 2024*. https://docs.apwg.org/reports/apwg_trends_report_q4_2024.pdf

Asiri, S., Xiao, Y., & Li, T. (2024). PhishTransformer: A Novel Approach to Detect Phishing Attacks Using URL Collection and Transformer. *Electronics*, *13*(1), 30. https://doi.org/10.3390/electronics13010030

Azhar, M., Amjad, A., Arman, M., & Dewi, D. A. (2026). Multimodal Emotion Detection in Low-Resource Languages Using Lightweight Transformer Architectures: A Dual-Level Fusion Framework Integrating DistilBERT, CNN-BiGRU, and MobileViT for Efficient Real-Time Urdu Affective Computing. *Information*, *17*(5), 458. https://doi.org/10.3390/info17050458

Bahdanau, D., Cho, K., & Bengio, Y. (2014). *Neural Machine Translation by Jointly Learning to Align and Translate*. http://arxiv.org/abs/1409.0473

Barik, K., Misra, S., & Mohan, R. (2025). Web-based phishing URL detection model using deep learning optimization techniques. *International Journal of Data Science and Analytics*, *20*(5), 4449–4471. https://doi.org/10.1007/s41060-025-00728-9

Butnaru, A., Mylonas, A., & Pitropakis, N. (2021). Towards Lightweight URL-Based Phishing Detection. *Future Internet*, *13*(6), 154. https://doi.org/10.3390/fi13060154

Cao, T., Huang, C., Li, Y., Wang, H., He, A., Oo, N., & Hooi, B. (2025). PhishAgent: A Robust Multimodal Agent for Phishing Webpage Detection. *Proceedings of the AAAI Conference on Artificial Intelligence*, *39*(27), 27869–27877. https://doi.org/10.1609/aaai.v39i27.35003

Cisse, A. H., & Ishimaru, S. (2026). Detect and Repair: Robust Self-Supervised Wearable Sensing Under Missing Modalities. *Sensors*, *26*(8), 2419. https://doi.org/10.3390/s26082419

Duy, P. T., Minh, V. Q., Dang, B. T. H., Son, N. D. H., Quyen, N. H., & Pham, V.-H. (2024). A Study on Adversarial Sample Resistance and Defense Mechanism for Multimodal Learning-Based Phishing Website Detection. *IEEE Access*, *12*, 137805–137824. https://doi.org/10.1109/ACCESS.2024.3436812

Faris, H., & Yazid, S. (2021). Phishing Web Page Detection Methods: URL and HTML Features Detection. *2020 IEEE International Conference on Internet of Things and Intelligence System (IoTaIS)*, 167–171. https://doi.org/10.1109/IoTaIS50849.2021.9359694

Goldenits, G., König, P., Raubitzek, S., & Ekelhart, A. (2026). Small Language Models for Phishing Website Detection: Cost, Performance, and Privacy Trade-Offs. *Journal of Cybersecurity and Privacy*, *6*(2), 48. https://doi.org/10.3390/jcp6020048

Gupta, B. B., Arachchilage, N. A. G., & Psannis, K. E. (2018). Defending Against Phishing Attacks: Taxonomy of Methods, Current Issues and Future Directions. *Telecommunication Systems*, *67*(2), 247–267. https://doi.org/10.1007/s11235-017-0334-z

Haq, Q. E. ul, Faheem, M. H., & Ahmad, I. (2024). Detecting Phishing URLs Based on a Deep Learning Approach to Prevent Cyber-Attacks. *Applied Sciences*, *14*(22), 10086. https://doi.org/10.3390/app142210086

Howard, A., Sandler, M., Chen, B., Wang, W., Chen, L.-C., Tan, M., Chu, G., Vasudevan, V., Zhu, Y., Pang, R., Adam, H., & Le, Q. (2019). Searching for MobileNetV3. *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, 1314–1324. https://doi.org/10.1109/ICCV.2019.00140

Ibrahim, M., Al-Wadi, A., & Elhafiz, R. (2024). Security Analysis for Smart Healthcare Systems. *Sensors*, *24*(11), 3375. https://doi.org/10.3390/s24113375

Jain, S., & Wallace, B. C. (2019). Attention is not Explanation. In J. Burstein, C. Doran, & T. Solorio (Eds.), *Proceedings of the 2019 Conference of the North* (pp. 3543–3556). Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1357

Jin, D., He, C., Zou, Q., Qin, Y., & Wang, B. (2025). Source Code Vulnerability Detection Based on Joint Graph and Multimodal Feature Fusion. *Electronics*, *14*(5), 975. https://doi.org/10.3390/electronics14050975

Kim, J., Gu, S., Kim, Y., Lee, S., & Kang, C. (2025). A Multimodal Voice Phishing Detection System Integrating Text and Audio Analysis. *Applied Sciences*, *15*(20), 11170. https://doi.org/10.3390/app152011170

Lakshmi, G., & P, S. (2026). LightPhishAI: A Lightweight Multimodal Feature Extraction and Fusion Framework for Real-Time Phishing Detection on IoT Devices. *International Journal of Electronics and Communication Engineering*, *13*(3), 241–265. https://doi.org/10.14445/23488549/IJECE-V13I3P120

Lee, J., Lim, P., Hooi, B., & Divakaran, D. M. (2024). Multimodal Large Language Models for Phishing Webpage Detection and Identification. *2024 APWG Symposium on Electronic Crime Research (ECrime)*, 1–13. https://doi.org/10.1109/eCrime66200.2024.00007

Li, W., Manickam, S., & Chong, Y.-W. (2025). FedPhishLLM: A Privacy-Preserving and Explainable Phishing Detection Mechanism using Federated Learning and LLMs. *Journal of King Saud University Computer and Information Sciences*, *37*(8), 252. https://doi.org/10.1007/s44443-025-00267-0

Li, W., Manickam, S., Laghari, S. U. A., & Chong, Y.-W. (2023). Uncovering the Cloak: A Systematic Review of Techniques Used to Conceal Phishing Websites. *IEEE Access*, *11*, 71925–71939. https://doi.org/10.1109/ACCESS.2023.3293063

Lin, R., & Hu, H. (2023). MissModal: Increasing Robustness to Missing Modality in Multimodal Sentiment Analysis. *Transactions of the Association for Computational Linguistics*, *11*, 1686–1702. https://doi.org/10.1162/tacl_a_00628

Lin, Y., Liu, R., Divakaran, D. M., Ng, J. Y., Chan, Q. Z., Lu, Y., Si, Y., Zhang, F., & Dong, J. S. (2021). Phishpedia: A Hybrid Deep Learning Based Approach to Visually Identify Phishing Webpages. *30th USENIX Security Symposium (USENIX Security 21)*, 3793–3810. https://www.usenix.org/conference/usenixsecurity21/presentation/lin

Liu, R., Lin, Y., Yang, X., Ng, S. H., Divakaran, D. M., & Dong, J. S. (2022). Inferring Phishing Intention via Webpage Appearance and Dynamics: A Deep Vision Based Approach. *31st USENIX Security Symposium (USENIX Security 22)*, 1633–1650. https://www.usenix.org/conference/usenixsecurity22/presentation/liu-ruofan

Liu, X., Zhao, J., & Chen, G. (2026). A Multi-Modal Remote Sensing Image Classification Method Based on Physics-Guided Feature Decoupling and Adaptive Collaborative Fusion of HSI–LiDAR. *Algorithms*, *19*(6), 473. https://doi.org/10.3390/a19060473

Lu, J., Batra, D., Parikh, D., & Lee, S. (2019). ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d Alché-Buc, E. Fox, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems* (Vol. 32). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2019/file/c74d97b01eae257e44aa9d5bade97baf-Paper.pdf

Luong, T., Pham, H., & Manning, C. D. (2015). Effective Approaches to Attention-based Neural Machine Translation. In L. Màrquez, C. Callison-Burch, & J. Su (Eds.), *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing* (pp. 1412–1421). Association for Computational Linguistics. https://doi.org/10.18653/v1/D15-1166

Moghimi, M., & Varjani, A. Y. (2016). New Rule-Based Phishing Detection Method. *Expert Systems with Applications*, *53*, 231–242. https://doi.org/https://doi.org/10.1016/j.eswa.2016.01.028

Mossano, M., Kulyk, O., Berens, B. M., Häußler, E. M., & Volkamer, M. (2023). Influence of URL Formatting on Users' Phishing URL Detection. *Proceedings of the 2023 European Symposium on Usable Security*, 318–333. https://doi.org/10.1145/3617072.3617111

Myagmarsuren, D., Wu, H., & Wang, A. (2026). Multimodal Uncertainty-Aware Gating Fusion and Iterative Feedback Refinement for HSI-LiDAR Open-Set Classification. *Remote Sensing*, *18*(12), 1963. https://doi.org/10.3390/rs18121963

Nasir, N., Waseem, S. S., Bilal, M., & Hassan, S. R. (2026). IoT-Oriented Security for Small Sensor Systems Using DnCNN Denoising and Multimodal Feature Fusion for Image Forgery Detection. *Sensors*, *26*(4), 1172. https://doi.org/10.3390/s26041172

Ogawa, Y., Kimura, T., & Cheng, J. (2022). Deep Learning Based Sequential Phishing Detection. *IEICE Communications Express*, *11*(4), 2021XBL0212. https://doi.org/10.1587/comex.2021XBL0212

Ojewumi, T. O., Ogunleye, G. O., Oguntunde, B. O., Folorunsho, O., Fashoto, S. G., & Ogbu, N. (2022). Performance Evaluation of Machine Learning Tools for Detection of Phishing Attacks on Web Pages. *Scientific African*, *16*, e01165. https://doi.org/10.1016/j.sciaf.2022.e01165

Omari, K. (2023). Comparative Study of Machine Learning Algorithms for Phishing Website Detection. *International Journal of Advanced Computer Science and Applications*, *14*(9), 2023. https://doi.org/10.14569/IJACSA.2023.0140945

Omari, K., & Oukhatar, A. (2025). Advanced Phishing Website Detection with SMOTETomek-XGB: Addressing Class Imbalance for Optimal Results. *Procedia Computer Science*, *252*, 289–295. https://doi.org/10.1016/j.procs.2024.12.031

Prasad, A., & Chandra, S. (2024). PhiUSIIL: A Diverse Security Profile Empowered Phishing URL Detection Framework Based on Similarity Index and Incremental Learning. *Computers & Security*, *136*, 103545. https://doi.org/https://doi.org/10.1016/j.cose.2023.103545

Qureshi, R., & Koo, I. (2026). A Comprehensive Survey of Cybersecurity Threats and Data Privacy Issues in Healthcare Systems. *Applied Sciences*, *16*(3), 1511. https://doi.org/10.3390/app16031511

Rao, R. S., Kondaiah, C., Pais, A. R., & Lee, B. (2025). A Hybrid Super Learner Ensemble for Phishing Detection on Mobile Devices. *Scientific Reports*, *15*(1), 16839. https://doi.org/10.1038/s41598-025-02009-8

Ravichandran, A., Kathirvel Murugan, T., Govindaraj, L., & M, V. (2026). Explainable Multimodal Feature Fusion Networks for Parkinson's Disease Prediction. *Frontiers in Digital Health*, *8*. https://doi.org/10.3389/fdgth.2026.1771281

Roy, S. S., & Nilizadeh, S. (2026). PhishLang: A Real-Time, Fully Client-Side Phishing Detection Framework Using MobileBERT. *Proceedings 2026 Network and Distributed System Security Symposium*. https://doi.org/10.14722/ndss.2026.231037

Shaiba, H., S. Alzahrani, J., M. Eltahir, M., Marzouk, R., Mohsen, H., & Ahmed Hamza, M. (2022). Hunger Search Optimization with Hybrid Deep Learning Enabled Phishing Detection and Classification Model. *Computers, Materials & Continua*, *73*(3), 6425–6441. https://doi.org/10.32604/cmc.2022.031625

Solanes, J. E., Francés-Falip, A., & Linares-Pellicer, J. (2026). Domain-Transportable Latent Summaries for Robust Multimodal Autism Phenotyping Under Missing Modality Blocks. *Electronics*, *15*(11), 2422. https://doi.org/10.3390/electronics15112422

Srivastava, N., Hinton, G., Krizhevsky, A., & Salakhutdinov, R. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. In *Journal of Machine Learning Research* (Vol. 15). http://jmlr.org/papers/v15/srivastava14a.html

Suwarno, S., Capricornness, V., & Christian, Y. (2026). Browser Extension-Based Machine Learning Implementation for Phishing URL Detection Using Logistic Regression Classification. *Komputa : Jurnal Ilmiah Komputer Dan Informatika*, *15*(1). https://doi.org/10.34010/komputa.v15i1.18882

Syafiq Rohmat Rose, M. A., Basir, N., Nabila Rafie Heng, N. F., Juana Mohd Zaizi, N., & Saudi, M. M. (2022). Phishing Detection and Prevention using Chrome Extension. *2022 10th International Symposium on Digital Forensics and Security (ISDFS)*, 1–6. https://doi.org/10.1109/ISDFS55398.2022.9800826

Tamal, M. A., Islam, M. K., Bhuiyan, T., Sattar, A., & Prince, N. U. (2024). Unveiling suspicious phishing attacks: enhancing detection with an optimal feature vectorization algorithm and supervised machine learning. *Frontiers in Computer Science*, *6*. https://doi.org/10.3389/fcomp.2024.1428013

Tang, L., & Mahmoud, Q. H. (2021). A Survey of Machine Learning-Based Solutions for Phishing Website Detection. *Machine Learning and Knowledge Extraction*, *3*(3), 672–694. https://doi.org/10.3390/make3030034

Tang, L., & Mahmoud, Q. H. (2022). A Deep Learning-Based Framework for Phishing Website Detection. *IEEE Access*, *10*, 1509–1521. https://doi.org/10.1109/ACCESS.2021.3137636

Thakur, K., Ali, M. L., Obaidat, M. A., & Kamruzzaman, A. (2023). A Systematic Review on Deep-Learning-Based Phishing Email Detection. *Electronics*, *12*(21), 4545. https://doi.org/10.3390/electronics12214545

Vajrobol, V., Gupta, B. B., & Gaurav, A. (2024). Mutual Information Based Logistic Regression for Phishing URL Detection. *Cyber Security and Applications*, *2*, 100044. https://doi.org/10.1016/j.csa.2024.100044

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. ukasz, & Polosukhin, I. (2017). Attention is All you Need. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

Vulfin, A., Sulavko, A., Vasiliev, V., Minko, A., Kirillova, A., & Samotuga, A. (2026). A Multimodal Phishing Website Detection System Using Explainable Artificial Intelligence Technologies. *Machine Learning and Knowledge Extraction*, *8*(1), 11. https://doi.org/10.3390/make8010011

Wang, H., Fang, Y., Wang, X., & Min, F. (2026). Three-Way Multimodal Learning with Severely Missing Modalities. *Information*, *17*(4), 384. https://doi.org/10.3390/info17040384

Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). MINILM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers. *Proceedings of the 34th International Conference on Neural Information Processing Systems, NIPS '20*. https://proceedings.neurips.cc/paper_files/paper/2020/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

Wang, X., Wu, J., Zhang, P., & Yu, Z. (2025). Language-Driven Cross-Attention for Visible–Infrared Image Fusion Using CLIP. *Sensors*, *25*(16), 5083. https://doi.org/10.3390/s25165083

Wang, Y., Ma, W., Xu, H., Liu, Y., & Yin, P. (2023). A Lightweight Multi-View Learning Approach for Phishing Attack Detection Using Transformer with Mixture of Experts. *Applied Sciences*, *13*(13), 7429. https://doi.org/10.3390/app13137429

Wangchuk, T., & Gonsalves, T. (2025). Multimodal Phishing Detection on Social Networking Sites: A Systematic Review. *IEEE Access*, *13*, 103405–103416. https://doi.org/10.1109/ACCESS.2025.3579584

Waseem, S. S., Shabbir, N., Hassan, S. R., & Lee, K. (2026). Sensors-Driven Multimodal Deepfake Detection: A Cross-Attention Fusion Approach with Adaptive Modality Gating. *Sensors*, *26*(12), 3695. https://doi.org/10.3390/s26123695

Woo, S., Lee, S., Park, Y., Nugroho, M. A., & Kim, C. (2023). Towards Good Practices for Missing Modality Robust Action Recognition. *Proceedings of the AAAI Conference on Artificial Intelligence*, *37*(3), 2776–2784. https://doi.org/10.1609/aaai.v37i3.25378

Xiong, H., & Dai, M. (2026). FedMIR: Multimodal Federated Learning with Missing Modality Imputation and Distribution-Aware Routing. *Sensors*, *26*(10), 2954. https://doi.org/10.3390/s26102954

Yang, P., Zhao, G., & Zeng, P. (2019). Phishing Website Detection Based on Multidimensional Features Driven by Deep Learning. *IEEE Access*, *7*, 15196–15209. https://doi.org/10.1109/ACCESS.2019.2892066

Yoon, J.-H., Buu, S.-J., & Kim, H.-J. (2024). Phishing Webpage Detection via Multi-Modal Integration of HTML DOM Graphs and URL Features Based on Graph Convolutional and Transformer Networks. *Electronics*, *13*(16), 3344. https://doi.org/10.3390/electronics13163344

Yuan, X., Wang, J., Yan, T., & Qi, F. (2026). LLM-Based Multimodal Feature Extraction and Hierarchical Fusion for Phishing Email Detection. *Electronics*, *15*(2), 368. https://doi.org/10.3390/electronics15020368

Zara, U., Ayyub, K., Ullah Khan, H., Daud, A., Alsahfi, T., & Gulzar Ahmad, S. (2024). Phishing Website Detection Using Deep Learning Models. *IEEE Access*, *12*, 167072–167087. https://doi.org/10.1109/ACCESS.2024.3486462

Zhang, C., Han, Z., cui, yajie, Fu, H., Zhou, J. T., & Hu, Q. (2019). CPM-Nets: Cross Partial Multi-View Networks. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d Alché-Buc, E. Fox, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems* (Vol. 32). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2019/file/11b9842e0a271ff252c1903e7132cd68-Paper.pdf

Zhang, J., Ge, K., Xun, L., Sun, X., Xiong, W., Zou, M., Zhong, J., & Li, T. (2022). MFCD-Net: Cross Attention Based Multimodal Fusion Network for DPC Imagery Cloud Detection. *Remote Sensing*, *14*(16), 3905. https://doi.org/10.3390/rs14163905

Zhang, X., Song, Q., & Liu, G. (2022). Multimodal Image Aesthetic Prediction with Missing Modality. *Mathematics*, *10*(13), 2312. https://doi.org/10.3390/math10132312

Zhong, C., Zeng, S., & Zhu, H. (2025). Adaptive Multimodal Fusion with Cross-Attention for Robust Scene Segmentation and Urban Economic Analysis. *Applied Sciences*, *15*(1), 438. https://doi.org/10.3390/app15010438

Zhu, E., Chen, Y., Ye, C., Li, X., & Liu, F. (2019). OFS-NN: An Effective Phishing Websites Detection Model Based on Optimal Feature Selection and Neural Network. *IEEE Access*, *7*, 73271–73284. https://doi.org/10.1109/ACCESS.2019.2920655

LAMPIRAN

Penegasan istilah dalam proposal skripsi ini berfungsi untuk menjelaskan definisi operasional dari kata atau istilah kunci yang digunakan. Pembatasan dan klarifikasi ini sangat krusial untuk menghindari perbedaan penafsiran (misinterpretasi) antara penulis dan pembaca, serta untuk menjaga ketegasan fokus pembahasan pada arsitektur *PhishCross* yang diusulkan. Berikut adalah daftar istilah kunci yang disusun secara alfabetis beserta definisi operasionalnya yang diterapkan dalam penelitian ini:

1. *AdamW Optimizer*: Algoritma optimasi penurun gradien adaptif yang menyertakan regulasi pemotongan bobot (*decoupled weight decay*). Dalam penelitian ini, *AdamW* digunakan untuk memperbarui nilai parameter bobot selama proses pelatihan model dengan laju pembelajaran awal sebesar $1 \times 10 - 3$ dan koefisien *weight decay* sebesar $1 \times 10 - 3$.
2. *All-MiniLM-L6-v2*: Model bahasa terkompresi berbasis arsitektur *transformer* yang memuat 22 juta parameter dan dilatih menggunakan teknik distilasi pengetahuan (*knowledge distillation*) dari model guru *BERT* yang berukuran raksasa. Dalam penelitian ini, model tersebut dibekukan (*frozen*) dan digunakan secara lokal sebagai ekstraktor fitur semantik untuk menghasilkan representasi HTML berdimensi 384 dari teks bersih halaman web.
3. *Asymmetric Cross-Attention*: Mekanisme atensi satu arah di mana matriks *Query* (Q) hanya diproyeksikan dari representasi fitur satu modalitas utama (representasi HTML), sedangkan matriks *Key* (K) dan *Value* (V) diproyeksikan dari penggabungan vertikal (*stacking*) modalitas pendukung lainnya (fitur URL dan visual *screenshot*).
4. *Binary Cross Entropy Loss* (BCE *Loss*): Fungsi kerugian (*loss function*) klasifikasi biner yang digunakan untuk mengukur tingkat kesalahan prediksi model selama proses pelatihan, di mana nilai kerugian tersebut

diperambatkan balik (*backpropagation*) melintasi lapisan model untuk memperbarui nilai parameter bobot.

5. *Client-Side*/Lingkungan Lokal: Pemrosesan dan eksekusi model klasifikasi yang dilakukan sepenuhnya pada perangkat lokal pengguna akhir tanpa bergantung pada kueri metadata eksternal (seperti API WHOIS atau status sertifikat SSL), guna meminimalkan latensi jaringan dan menjaga privasi riwayat penelusuran (*browsing history*) pengguna akhir.
6. *CosineAnnealingLR*: Fungsi penjadwal (*scheduler*) laju pembelajaran yang digunakan untuk menurunkan kecepatan belajar model secara bertahap mengikuti fungsi kosinus, mulai dari nilai maksimum awal sebesar $1 \times 10 - 3$ hingga batas minimum sebesar $1 \times 10 - 6$ sepanjang 30 *epoch* pelatihan.
7. *Depthwise Separable Convolution*: Teknik konvolusi teroptimasi yang digunakan untuk mereduksi beban komputasi perkalian matriks pada ekstraksi visual dengan memisahkan operasi konvolusi standar menjadi tahap konvolusi spasial per-saluran (*depthwise*) dan konvolusi proyeksi saluran (*pointwise*), sehingga menghemat parameter hingga 8 sampai 9 kali lipat.
8. *Early Stopping*: Protokol pengontrolan iterasi pelatihan model yang secara otomatis menghentikan proses pelatihan jika metrik evaluasi (*F1-Score*) pada subset validasi tidak mengalami peningkatan selama batas toleransi (*patience*) yang ditetapkan (yaitu sebesar 7 *epoch*) guna mencegah kondisi *overfitting*.
9. *False Positive Rate* (FPR): Metrik evaluasi kinerja model yang mengukur rasio halaman situs web sah (*legitimate*) yang secara keliru diklasifikasikan atau diblokir oleh model deteksi sebagai halaman situs *phishing*.
10. Format ONNX (*Open Neural Network Exchange*): Format model representasi terbuka yang digunakan untuk mengekspor arsitektur model dari ekosistem *PyTorch* agar dapat dijalankan secara teroptimasi

menggunakan mesin runtime ONNX lokal pada CPU perangkat pengguna akhir dengan validasi silang untuk konsistensi numerik.

11. *Frozen Encoders*: Kondisi di mana bobot parameter dari model pengekstraksi fitur pra-latih (*pre-trained encoders*) dikunci secara permanen selama proses pelatihan model klasifikasi berlangsung guna menjaga stabilitas representasi dan mencegah kebocoran data (*data leakage*).
12. *Intermediate*/*Representation-Level Fusion*: Pendekatan fusi multimodal yang menggabungkan representasi fitur dari berbagai modalitas masukan pada lapisan tersembunyi (*hidden layers*) di dalam jaringan saraf guna memfasilitasi interaksi fitur lintas-modal yang lebih kompleks.
13. HTML-*Queried Cross-Attention with Residual Bypass*: Desain fusi asimetris pada arsitektur *PhishCross* di mana representasi semantik HTML bertindak sebagai *Query* ($Q \in \mathbb{R}1 \times d$) untuk mengekstraksi informasi relasional dari URL dan visual *screenshot* (sebagai *Key* $K \in \mathbb{R}2 \times d$ dan *Value* $V \in \mathbb{R}2 \times d$) tanpa melakukan *self-attention* terhadap dirinya sendiri, sementara kelengkapan informasi semantik HTML tetap dialirkan langsung menuju kepala klasifikasi menggunakan koneksi sisa (*residual connection*).
14. *Data Leakage*: Isu metodologis di mana informasi dari data pengujian (*test set*) atau label secara tidak sengaja terserap atau masuk ke dalam proses pelatihan model, yang dalam penelitian ini dicegah melalui pembatasan subset validasi terisolasi dan normalisasi citra visual tanpa menghitung ulang statistik dataset.
15. *Class Imbalance*: Kondisi ketimpangan jumlah sampel antara kelas mayoritas (*legitimate*) dan kelas minoritas (*phishing*) pada dataset, yang diatasi pada data *loader PyTorch* menggunakan teknik *WeightedRandomSampler* agar model tidak bias selama pelatihan.
16. *Missing Modality*: Kondisi pengujian di mana salah satu modalitas masukan (seperti alamat URL atau gambar tangkapan layar) tidak

tersedia atau gagal dimuat pada fase inferensi akibat kendala jaringan atau manipulasi oleh penyerang siber.

17. *MobileNetV3-Small*: Arsitektur jaringan saraf konvolusional (CNN) ringan untuk pemrosesan citra yang memanfaatkan operasi *depthwise separable convolution* dan *blok Squeeze-and-Excitation* (SE) untuk mereduksi beban komputasi. Di dalam arsitektur *PhishCross*, model ini digunakan untuk mengekstrak fitur spasial citra tangkapan layar situs web berukuran 224×224 piksel menjadi vektor representasi berdimensi 576.
18. *Modality Dropout*: Teknik regularisasi selama proses pelatihan model yang secara acak menonaktifkan (mengganti dengan vektor nol) representasi dari suatu modalitas masukan dengan probabilitas tertentu (ditetapkan sebesar 15% menggunakan masker *Bernoulli*) guna memaksa model mempelajari fitur alternatif yang redundan pada modalitas lain demi meningkatkan ketahanan.
19. *Multi-Head Attention* (MHA): Pengembangan operasi atensi yang menjalankan proyeksi perhatian secara paralel pada beberapa kepala independen untuk menangkap keterkaitan fitur pada berbagai subruang representasi (*subspaces*) yang berbeda secara simultan. Dalam penelitian ini, MHA menggunakan 4 head paralel dengan dimensi proyeksi internal masing-masing sebesar 32.
20. *Multi-Layer Perceptron* (MLP) *Classifier Head*: Lapisan kepala klasifikasi saraf tiruan *multi-layer perceptron* yang menerima vektor fusi akhir berdimensi 256 dan memprosesnya melalui struktur terhubung penuh (256-256-ReLU-dropout-2) untuk menghasilkan probabilitas prediksi keputusan akhir.
21. *Multimodal Deep Learning*: Pendekatan pembelajaran mendalam (*deep learning*) yang mengintegrasikan representasi fitur dari beberapa saluran sensorik atau jenis masukan yang berbeda untuk memecahkan satu tugas klasifikasi, yang dalam penelitian ini menggabungkan URL, kode HTML, dan citra tangkapan layar (*screenshot*).

22. *Homoglyph Attack* & *Punycode*: Taktik manipulasi visual alamat web di mana penyerang mendaftarkan nama domain internasional berbasis *Punycode* menggunakan karakter *non*-ASCII (seperti alfabet Sirilik) yang secara visual identik dengan alfabet Latin standar untuk mengelabui korban.
23. *Squeeze-and-Excitation* (SE) *Block*: Blok perhatian saluran (*channel-wise attention*) pada *MobileNetV3-Small* yang menerapkan operasi *squeeze* (mereduksi spasial dimensi citra melalui *global average pooling*) dan *excitation* (menggunakan MLP kecil) untuk menghitung bobot penting setiap saluran guna memprioritaskan fitur visual yang paling dominan.
24. *Stratified Split*: Strategi pembagian dataset secara dinamis (menggunakan rasio 85:15 untuk data *training* dan *validation*) yang secara ketat mempertahankan proporsi distribusi kelas target yang seimbang pada kedua subset guna mencegah masalah kebocoran data (*data leakage*).
25. *Ablation Study*: Metode eksperimen terkontrol dalam pengembangan model pembelajaran mendalam yang dilakukan dengan cara menghapus atau nonaktifkan komponen tertentu dari sistem secara sistematis (seperti menghapus salah satu modalitas masukan atau menonaktifkan teknik *modality dropout*) guna mengukur dan mengevaluasi kontribusi spesifik dari komponen tersebut terhadap kinerja keseluruhan model.
26. *Taktik Evasion*: Berbagai teknik yang digunakan oleh penyerang siber untuk menyembunyikan karakteristik situs *phishing* dari deteksi otomatis, seperti enkripsi kode sumber secara dinamis (J*avaScript-based obfuscation*), penyembunyian halaman (*cloaking*), pemalsuan alamat visual (*homoglyph attack*), hingga pembuatan halaman dinamis (*dynamic DOM rendering*).
27. *McNemar's Test*: Uji statistik non-parametrik berpasangan (*paired test*) yang digunakan untuk melakukan validasi statistik komparatif atas

perbedaan performa (prediksi benar-salah) antara arsitektur *PhishCross* dan model pembanding (*baseline*) pada sampel data uji (*test set*) yang identik.

28. URL *Character-Level* CNN *Encoder*: Modul pengekstraksi fitur URL pada arsitektur *PhishCross* yang memproses urutan karakter alamat web secara langsung tanpa bergantung pada kamus kosakata luar (*vocabulary-free*) menggunakan tiga filter konvolusi satu dimensi paralel (dengan ukuran *kernel* 3, 5, dan 7) dan dilatih secara penuh dari awal (*end-to-end trainable*).
29. *Website Phishing*: Bentuk kejahatan siber yang mengandalkan rekayasa sosial (*social engineering*) untuk memanipulasi psikologi korban agar menyerahkan data sensitif seperti kredensial perbankan dan kata sandi melalui situs web tiruan yang mereplikasi tampilan portal resmi dari institusi sasaran. Dalam penelitian ini, deteksi dibatasi pada analisis berbasis konten lokal halaman web (URL mentah, teks HTML yang terlihat, dan tangkapan layar) tanpa melibatkan metadata eksternal.
30. *Zero-Day Phishing*: Skenario serangan *phishing* atau *early-stage phishing* yang baru dilaporkan dalam kurun waktu 24-72 jam pertama sejak URL berbahaya muncul, di mana karakteristiknya belum tercatat dalam basis data reputasi atau belum sepenuhnya terwakili oleh dataset statis.